

Mateus Cichelero da Silva

**MÉTODOS DE INTELIGÊNCIA ARTIFICIAL PARA
DIAGNÓSTICO DE DEFEITOS EM MÁQUINAS ROTATIVAS**

Trabalho de Conclusão de Curso
submetido ao Departamento de
Engenharia Elétrica e Eletrônica da
Universidade Federal de Santa Catarina
para a obtenção do título de Bacharel
em Engenharia Elétrica.

Orientador: Prof. Dr. Márcio Holsbach
Costa

Coorientador: Eng. Gustavo Leão
Mourão

Florianópolis
2018

Ficha de identificação da obra elaborada pelo autor
através do Programa de Geração Automática da Biblioteca Universitária
da UFSC.

Silva, Mateus Cichelero da
Métodos de inteligência artificial para
diagnóstico de defeitos em máquinas rotativas /
Mateus Cichelero da Silva ; orientador, Márcio
Holsbach Costa, coorientador, Gustavo Leão
Mourão, 2018.

94 p.

Trabalho de Conclusão de Curso (graduação) -
Universidade Federal de Santa Catarina, Centro
Tecnológico, Graduação em Engenharia Elétrica,
Florianópolis, 2018.

Inclui referências.

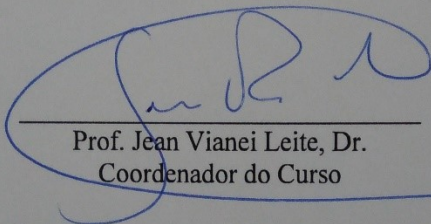
1. Engenharia Elétrica. 2. Manutenção Preditiva.
3. Machine Learning. 4. Inteligência Artificial. I.
Costa, Márcio Holsbach . II. Mourão, Gustavo Leão .
III. Universidade Federal de Santa Catarina.
Graduação em Engenharia Elétrica. IV. Título.

Mateus Cichelero da Silva

MÉTODOS DE INTELIGÊNCIA ARTIFICIAL PARA DIAGNÓSTICO DE DEFEITOS EM MÁQUINAS ROTATIVAS

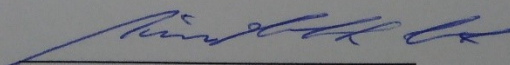
Este Trabalho foi julgado adequado para obtenção do Título de Bacharel
em Engenharia Elétrica e aprovado em sua forma final pela Banca
Examinadora

Florianópolis, 30 de Novembro de 2018.

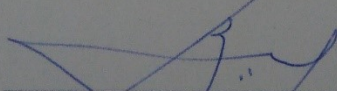


Prof. Jean Viane Leite, Dr.
Coordenador do Curso

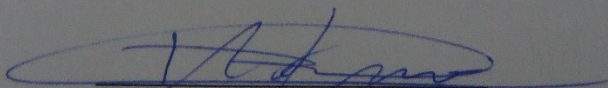
Banca Examinadora:



Prof. Márcio Holsbach Costa, Dr.
Orientador
Universidade Federal de Santa Catarina



Prof. José Carlos M. Bermudez, Dr.
Universidade Federal de Santa Catarina



Tiago K. Matsuo, Eng. MSc.
AQTech

RESUMO

Neste trabalho são apresentados conceitos, técnicas e padrões utilizados na área de manutenção preditiva de máquinas rotativas elétricas, mais precisamente na aplicação de métodos de inteligência artificial para diagnóstico de defeitos mecânicos através da análise de sinais de vibração. Um cenário de experimentos foi configurado através da utilização da base de dados de defeitos mecânicos MAFAULDA, que conta com seis condições distintas de saúde de máquinas rotativas elétricas. Estes dados são tratados por meio de técnicas de pré-processamento para extração de um vetor de características, utilizado como entrada para cinco métodos distintos de classificação: *k-nearest neighbors* (*k*-NN), Naive Bayes, *Support Vector Machine* (SVM), Regressão Logística e Redes Neurais Artificiais. São definidas métricas de desempenho para comparação dos métodos analisados, como a acurácia e sensibilidade. Por fim, testes estatísticos de hipótese são aplicados para confirmar a distinção de desempenho dos classificadores e um ranking é definido.

Palavras-chave: Manutenção Preditiva. Machine Learning. Inteligência Artificial.

ABSTRACT

This work presents concepts, techniques and standards used in the field of predictive maintenance of electric machines, more precisely in the application of artificial intelligence methods for the diagnosis of mechanical defects through the analysis of vibration signals. An experimental scenario was set up using the MAFAULDA mechanical fault database, which has six distinct machine health conditions. These data are treated by preprocessing techniques to obtain a vector of characteristics, to be used as input for five distinct classification methods: k-nearest neighbors (k-NN), Naive Bayes, Support Vector Machine (SVM), Logistic Regression, and Artificial Neural Networks. Performance metrics are applied for comparison of the analyzed methods, such as accuracy and sensitivity. Finally, statistical tests of hypothesis are applied to confirm the distinction of performance of the classifiers, and a ranking is defined.

Keywords: Predictive Maintenance. Machine Learning. Artificial Intelligence

LISTA DE FIGURAS

| | |
|--|----|
| Figura 1 - Projeção, por área de aplicação, do valor gerado na indústria de energia por meio da transformação digital. | 22 |
| Figura 2 - Visão em corte do estator, rotor e eixo em um motor elétrico de corrente contínua. | 28 |
| Figura 3 - Mancal de deslizamento. | 29 |
| Figura 4 - Mancal de rolamento | 30 |
| Figura 5 - Exemplo de acelerômetro piezoelétrico..... | 32 |
| Figura 6 - Esquema de funcionamento de um acelerômetro. | 33 |
| Figura 7 - Discrepância entre o eixo de simetria e o eixo de rotação. | 34 |
| Figura 8 - Tipos de desbalanceamento (em ordem): estático, acoplado e dinâmico. | 35 |
| Figura 9 - Tipos de desalinhamento: (a) paralelo, (b) angular e (c) combinado. | 36 |
| Figura 10 - Elementos de um mancal de rolamento. | 37 |
| Figura 11 - Representação de um mesmo sinal no domínio do (1) tempo e (2) frequência. | 38 |
| Figura 12 - Comportamento do espectro de sinal de vibração na presença de defeito de desbalanceamento. | 39 |
| Figura 13 - Espectro proveniente de máquinas com (a) Desalinhamento Angular e (b) Desalinhamento Paralelo. | 40 |
| Figura 14 - Estrutura para diagnóstico de falhas utilizado na área de engenharia de operação e manutenção. | 42 |
| Figura 15 - Gráfico da função Sigmóide. | 43 |
| Figura 16 - Regressão Logística com fronteiras de decisão linear e polinômica. | 44 |
| Figura 17 - Representação do diagrama k -NN. Dependendo do número k selecionado, a amostra de teste (<i>Test sample</i>) pode ser classificada como positiva ($k = 1$ e $k = 5$) ou negativa ($k = 3$). | 45 |
| Figura 18 - Conjunto de dados inicial. | 46 |
| Figura 19 - Dados com separador adicionado. | 46 |
| Figura 20 - Dados transformados. | 47 |
| Figura 21 - Neurônio biológico (a) e estrutura de uma Rede Neural Artificial (b) | 49 |
| Figura 22 - Diagrama - matriz confusão..... | 51 |
| Figura 23 - Cálculo dos elementos da matriz confusão para casos de múltiplas classes..... | 52 |
| Figura 24 - Bancada de simulação SpectraQuest e disposição dos sensores. | 56 |

| | |
|---|----|
| Figura 25 - Defeito no mancal de rolamento: (a) posição invertida (b) não invertida. | 57 |
| Figura 26 - Espectro do sinal do tacômetro da máquina girando a 1200 RPM. | 60 |
| Figura 27 - Processo de <i>Data Augmentation</i> dos sinais de vibração para a condição normal. | 61 |
| Figura 28 - Diagrama simplificado do procedimento padrão para treinamento e aplicação de classificadores automáticos. | 62 |
| Figura 29 - Relação desempenho (acurácia) em função do número de “vizinhos” considerados para aplicação do método <i>k</i> -NN. | 63 |
| Figura 30 - Modelo de rede neural artificial de camada oculta única. .. | 64 |
| Figura 31 - Relação desempenho (acurácia) × número de neurônios na camada oculta da rede neural artificial. | 65 |
| Figura 32 - Boxplot representando distribuição dos valores de acurácia para cada classificador analisado (n-amstral = 50 para cada método). .. | 75 |
| Figura 33 – Boxplot representando distribuição dos valores de sensibilidade para cada classificador analisado (n-amstral = 50 para cada método). | 75 |
| Figura 34 - Histogramas dos valores de acurácia para cada método analisado (n-amstral = 50 para cada classificador). | 77 |
| Figura 35 - Histogramas dos valores de sensibilidade para cada método analisado (n-amstral = 50 para cada classificador). | 78 |
| Figura 36 - Ordem dos testes t-Student pareados proposta por Irsoy, Yildiz e Alpaydin (2012). | 79 |
| Figura 37- Acelerômetro industrial IMI Sensors, modelo 601A01..... | 93 |
| Figura 38 - Acelerômetro triaxial IMI Sensors, modelo 604B31..... | 93 |
| Figura 39 - Montagem dos acelerômetros no mancal (a) interior e (b) exterior..... | 94 |

LISTA DE TABELAS

| | |
|--|----|
| Tabela 1 - Relação dos defeitos e frequências características. | 40 |
| Tabela 2 - Especificações da bancada experimental. | 55 |
| Tabela 3 - Número de casos coletados para cada tipo de defeito simulado. | 58 |
| Tabela 4 - Sinais do vetor de características após pré-processamento. . | 59 |
| Tabela 5 - Matriz confusão – Regressão Logística - Condição Normal. | 68 |
| Tabela 6- Matriz confusão – Regressão Logística - Desbalanceamento | 68 |
| Tabela 7 - Matriz confusão – Regressão Logística – Desalinhamento Vertical..... | 68 |
| Tabela 8- Matriz confusão – Regressão Logística – Desalinhamento Horizontal..... | 68 |
| Tabela 9- Matriz confusão – Regressão Logística – Mancal de rolamento na posição invertida..... | 68 |
| Tabela 10 - Matriz confusão – Regressão Logística – Mancal de rolamento na posição não invertida..... | 69 |
| Tabela 11 - Matriz confusão - k -NN - Condição Normal..... | 69 |
| Tabela 12 - Matriz confusão - k -NN - Desbalanceamento | 69 |
| Tabela 13 - Matriz confusão - k -NN - Desalinhamento Vertical | 69 |
| Tabela 14- Matriz confusão - k -NN - Desalinhamento Horizontal | 69 |
| Tabela 15- Matriz confusão - k -NN - Mancal de rolamento na posição invertida..... | 70 |
| Tabela 16 - Matriz confusão - k -NN - Mancal de rolamento na posição não invertida..... | 70 |
| Tabela 17- Matriz confusão - SVM - Condição Normal..... | 70 |
| Tabela 18 - Matriz confusão - SVM - Desbalanceamento | 70 |
| Tabela 19 - Matriz confusão - SVM - Desalinhamento Vertical..... | 70 |
| Tabela 20- Matriz confusão - SVM - Desalinhamento Horizontal..... | 71 |
| Tabela 21- Matriz confusão - SVM - Mancal de rolamento na posição invertida..... | 71 |
| Tabela 22 - Matriz confusão - SVM - Mancal de rolamento na posição não invertida..... | 71 |
| Tabela 23- Matriz confusão - Naive Bayes - Condição Normal | 71 |
| Tabela 24 - Matriz confusão - Naive Bayes - Desbalanceamento..... | 71 |
| Tabela 25 - Matriz confusão - Naive Bayes - Desalinhamento Vertical | 72 |
| Tabela 26- Matriz confusão - Naive Bayes - Desalinhamento Horizontal | 72 |
| Tabela 27- Matriz confusão - Naive Bayes - Mancal de rolamento na posição invertida | 72 |

| | |
|--|----|
| Tabela 28 - Matriz confusão - Naive Bayes - Mancal de rolamento na posição não invertida | 72 |
| Tabela 29- Matriz confusão - RNA - Condição Normal..... | 72 |
| Tabela 30 - Matriz confusão - RNA - Desbalanceamento | 73 |
| Tabela 31 - Matriz confusão - RNA - Desalinhamento Vertical..... | 73 |
| Tabela 32- Matriz confusão - RNA - Desalinhamento Horizontal | 73 |
| Tabela 33- Matriz confusão - RNA - Mancal de rolamento na posição invertida | 73 |
| Tabela 34 - Matriz confusão - RNA - Mancal de rolamento na posição não invertida..... | 73 |
| Tabela 35 - Comparação de desempenho entre as cinco técnicas analisadas..... | 74 |
| Tabela 36 - Características Acelerômetro 601A01 | 93 |
| Tabela 37 - Características Acelerômetro 604B31 | 93 |

LISTA DE ABREVIATURAS E SIGLAS

ANOVA - Análise de variância

csv - *comma-separated values*

CWRU - *Case Western Reserve University Bearing Database*

dc – Corrente contínua (*direct current*)

FFT – Transformada Rápida de Fourier (*Fast Fourier Transform*)

Hz – Hertz, unidade de frequência

IEEE - Instituto de Engenheiros Eletricistas e Eletrônicos

ISO – *International Organization for Standardization*

k-NN – *k-Nearest Neighbors*

MAFAULDA - *Machinery Fault Database*

NN – Vizinho mais próximo (*nearest neighbour*)

RNA – Redes Neurais Artificiais

RPM – Rotações por minuto

SVM - *Support Vector Machines*

SUMÁRIO

| | | |
|--------------|--|-----------|
| 1 | INTRODUÇÃO..... | 21 |
| 1.1 | JUSTIFICATIVA..... | 21 |
| 1.2 | OBJETIVOS | 23 |
| 1.2.1 | Objetivo geral | 23 |
| 1.2.2 | Objetivos específicos | 23 |
| 1.3 | METODOLOGIA | 24 |
| 1.3.1 | Procedimentos Metodológicos..... | 25 |
| 1.4 | ESTRUTURA DO TRABALHO | 25 |
| 2 | FUNDAMENTAÇÃO TEÓRICA | 27 |
| 2.1 | MÁQUINAS ROTATIVAS..... | 27 |
| 2.1.1 | Mancais de deslizamento e rolamento | 28 |
| 2.2 | MANUTENÇÃO PREDITIVA | 30 |
| 2.3 | ANÁLISE DE VIBRAÇÃO EM MÁQUINAS ROTATIVAS | 31 |
| 2.3.1 | Acelerômetro Piezoelétrico..... | 32 |
| 2.4 | PRINCIPAIS DEFEITOS MECÂNICOS EM MÁQUINAS | 33 |
| 2.4.1 | Desbalanceamento de rotores..... | 33 |
| 2.4.2 | Desalinhamento de eixos..... | 35 |
| 2.4.3 | Defeitos em mancais de rolamento | 36 |
| 2.5 | TÉCNICAS DE ANÁLISE PARA IDENTIFICAÇÃO DE DEFEITOS | 37 |
| 2.5.1 | Análise no domínio do tempo | 37 |
| 2.5.2 | Análise no domínio da frequência..... | 38 |
| 2.6 | MÉTODOS PARA CLASSIFICAÇÃO AUTOMÁTICA DE DEFEITOS | 41 |
| 2.6.1 | Regressão Logística | 42 |
| 2.6.2 | k-NN | 45 |
| 2.6.3 | SVM..... | 46 |
| 2.6.4 | Naive Bayes | 47 |

| | | |
|-------|---|-----------|
| 2.6.5 | Redes Neurais Artificiais..... | 49 |
| 2.7 | MÉTRICAS DE DESEMPENHO | 50 |
| 2.8 | TESTES ESTATÍSTICOS DE HIPÓTESE..... | 53 |
| 2.9 | BIBLIOTECAS PYTHON | 53 |
| 3 | MATERIAIS E MÉTODOS | 55 |
| 3.1 | DESCRIÇÃO DA BASE DE DADOS UTILIZADA | 55 |
| 3.1.1 | Configuração da aquisição de dados | 55 |
| 3.1.2 | Organização da base de dados | 57 |
| 3.2 | PRÉ-PROCESSAMENTO DE DADOS | 58 |
| 3.2.1 | Extração das características..... | 58 |
| 3.2.2 | Expansão do banco de dados para condições normais | 60 |
| 3.3 | PROCEDIMENTO PARA IMPLEMENTAÇÃO DE CLASSIFICADORES..... | 62 |
| 3.3.1 | Classificador Regressão Logística | 62 |
| 3.3.2 | Classificador k-NN..... | 63 |
| 3.3.3 | Classificador SVM | 63 |
| 3.3.4 | Classificador Naive Bayes | 64 |
| 3.3.5 | Classificador Rede Neural Artificial | 64 |
| 4 | ANÁLISE DOS RESULTADOS EXPERIMENTAIS..... | 67 |
| 4.1 | DESEMPENHO DOS CLASSIFICADORES..... | 67 |
| 4.1.1 | Classificador Regressão Logística | 67 |
| 4.1.2 | Classificador k-NN..... | 69 |
| 4.1.3 | Classificador SVM | 70 |
| 4.1.4 | Classificador Naive Bayes | 71 |
| 4.1.5 | Classificador Rede Neural Artificial | 72 |
| 4.2 | COMPARAÇÃO DA PERFORMANCE ENTRE OS DIFERENTES MÉTODOS | 74 |
| 4.2.1 | Testes estatísticos | 74 |
| 5 | CONCLUSÃO..... | 81 |
| 5.1 | SUGESTÕES PARA FUTUROS TRABALHOS | 81 |
| | REFERÊNCIAS..... | 83 |

| | |
|--|-----------|
| APÊNDICE A – Algoritmo de pré-processamento para condição normal.... | 89 |
| ANEXO A – Sensores de vibração utilizados na bancada experimental | 93 |

1 INTRODUÇÃO

A energia elétrica tornou-se indispensável para a manutenção e desenvolvimento da sociedade atual. Com isso, o setor de geração merece destaque e demanda estudos para otimização de seus processos, sendo a manutenção/gestão de ativos de grande relevância para a área. Neste contexto, o presente documento apresenta o trabalho de conclusão de curso do acadêmico Mateus Cichelero da Silva do curso de Engenharia Elétrica da Universidade Federal de Santa Catarina, que tem como tema a aplicação e análise de métodos de inteligência artificial para diagnóstico de defeitos em máquinas elétricas rotativas.

Na seção 1.1 são expostas justificativas para o assunto tratado, enquanto que na seção 1.2 são apresentados os objetivos do trabalho. Na seção 1.3 é realizada a caracterização metodológica do estudo realizado. Finalizando, a seção 1.4 apresenta a estrutura de apresentação.

1.1 JUSTIFICATIVA

A gestão de ativos na geração de energia elétrica depende em grande parte do adequado uso de máquinas e equipamentos, visando a maximização de sua disponibilidade e vida útil. Neste contexto, máquinas rotativas, como os geradores de energia elétrica, devem receber atenção significativa das equipes de manutenção, visto que sua operação pode exigir altos investimentos (CICHELERO, 2017).

Ao se analisar os investimentos envolvidos nesta gestão, principalmente no que diz respeito à manutenção dos ativos, destacam-se as elevadas parcelas destinadas ao custo homem-hora das equipes, elevado estoque de peças sobressalentes e redução da lucratividade devido à indisponibilidade e falha de ajustes nos geradores (AQX Instrumentação Eletrônica, 2008).

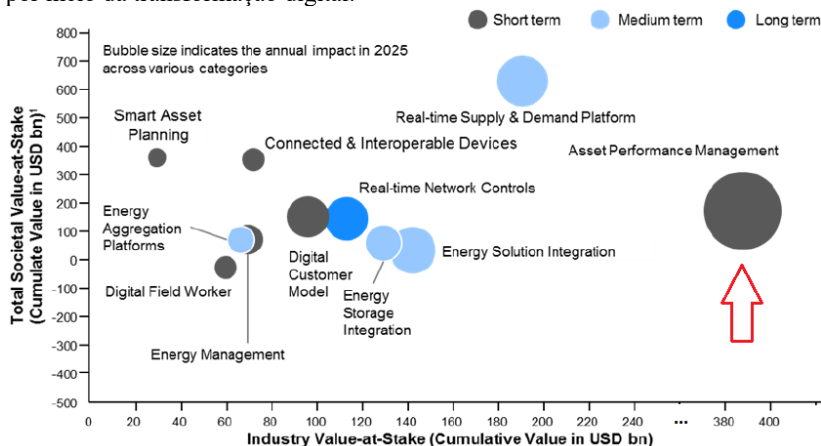
É neste contexto que se aplicam as técnicas de manutenção preditiva. O objetivo dessa filosofia de manutenção é estender ao máximo o tempo de funcionamento da máquina, planejando a parada para manutenção na iminência da falha. Isso só é possível com a realimentação de informações operacionais do sistema em análise como ferramenta para a tomada de decisões (FREITAS, 2012).

Tais considerações apontam a importância da adoção de estratégias otimizadas nas rotinas de manutenção. Ao se associar este cenário com a atual tendência de automatização e informatização dos processos associados à indústria de energia, é possível realizar uma projeção

otimista (WORLD ECONOMIC FORUM, 2016) no que diz respeito à criação de valor para o setor e sociedade nos próximos anos.

Segundo pesquisa realizada pelo Fórum Mundial de Economia (WORLD ECONOMIC FORUM, 2016) acerca dos impactos da transformação digital na indústria elétrica, a área de gestão de desempenho de ativos é a que possui maior potencial de crescimento. O estudo prevê ganhos no valor de 387 bilhões de dólares até o ano de 2025, conforme mostrado na Figura 1.

Figura 1 - Projeção, por área de aplicação, do valor gerado na indústria de energia por meio da transformação digital.



Fonte: WORLD ECONOMIC FORUM (2016) p.22

Assim, com a popularização de soluções em sensoriamento digital, a informação coletada encontra-se cada vez mais barata e abundante. Dessa forma, a utilização deste conjunto de dados pode contribuir para aumentar a eficiência em sistemas para manutenção preditiva. Métodos de inteligência artificial têm apresentado resultados relevantes dentro desta perspectiva (LIU et al., 2018).

Neste contexto, estudos do departamento de energia norte-americano apontam uma diminuição em 75% do número de falhas nas companhias que implementam esse tipo de estratégia (U.S. DEPARTMENT OF ENERGY, 2010).

Justifica-se, portanto, o investimento tanto da indústria quanto da academia em novos estudos e pesquisas na área. Além disso, a execução desse trabalho vai ao encontro dos interesses da empresa parceira AQTech Engenharia e Instrumentação, responsável pela infraestrutura e

apoio técnico necessários a este trabalho. Denota-se, por fim, o interesse pessoal do autor em conhecer mais sobre as técnicas e práticas relacionadas à aplicação de aprendizagem de máquina para um problema real e relevante.

1.2 OBJETIVOS

Segundo a literatura, a escolha dos objetivos em um trabalho de pesquisa científica deve traduzir o que se pretende alcançar durante tal processo. Deste modo, caracterizam-se o objetivo geral como a síntese do que se pretende alcançar e os objetivos específicos como a explicitação em detalhes dos desdobramentos do objetivo geral (SILVA; MENEZES, 2005).

Com isso, essa seção apresenta o objetivo geral e objetivos específicos do presente trabalho de conclusão de curso.

1.2.1 Objetivo geral

O presente trabalho tem como objetivo principal avaliar o desempenho de métodos de inteligência artificial aplicados ao diagnóstico de falhas em máquinas rotativas.

1.2.2 Objetivos específicos

Os objetivos específicos desse trabalho são:

- Identificar bancos de dados com sinais provenientes de máquinas rotativas que tenham seu estado de funcionamento (normal ou defeituoso) já classificado.
- Definir, dentre os diversos métodos existentes, um conjunto de técnicas de inteligência artificial que seja adequado ao problema proposto.
- Avaliar os métodos selecionados implementados em bibliotecas *open source* disponíveis na linguagem de programação Python.
- Treinar os sistemas implementados utilizando uma base de dados de defeitos já classificados.
- Validar os métodos implementados.

1.3 METODOLOGIA

Essa seção tem por objetivo apresentar o trabalho realizado seguindo as formas clássicas de classificação da metodologia científica (SILVA; MENEZES, 2005). Além disso, uma descrição dos principais procedimentos para sua elaboração é apresentada.

Do ponto de vista de sua natureza, o presente trabalho pode ser considerado como pesquisa aplicada, visto que busca gerar conhecimentos para aplicação prática em uma solução de engenharia.

Quanto à forma de abordagem do problema, por tratar da análise de sinais coletados das máquinas através da utilização de ferramental matemático e estatístico para geração de conhecimento, a pesquisa é classificada como quantitativa.

Por outro lado, sob a ótica de seus objetivos (GIL, 1991), apresenta-se como pesquisa exploratória, assumindo a forma de estudo de caso, objetivando proporcionar maior familiaridade com o problema.

Finalmente, do ponto de vista dos procedimentos técnicos, é possível ainda classificar o trabalho através das seguintes formas:

- Pesquisa bibliográfica, fazendo uso de materiais já publicados, como livros, normas técnicas, artigos científicos sobre o tema e bibliotecas abertas de códigos implementados e validados;
- Pesquisa documental, por ser elaborada a partir de dados que ainda não receberam tratamento analítico;
- Pesquisa experimental, onde objetos de estudo são determinados, as variáveis que seriam capazes de influenciá-los são selecionadas e formas de controle e observação dos efeitos que a variável produz no objeto são definidas;
- Pesquisa participante, que é desenvolvida através da interação entre o pesquisador e membros das situações investigadas. No trabalho desenvolvido, caracteriza-se como participante pelo contato com o corpo técnico de engenheiros da AQTech.

1.3.1 Procedimentos Metodológicos

Inicialmente foi realizada uma pesquisa bibliográfica acerca das principais técnicas de aprendizado de máquina utilizadas no contexto de diagnóstico de defeitos em máquinas rotativas, com o objetivo de se obter a base conceitual para o desenvolvimento do projeto. Conforme já citado, nesta etapa foram utilizados materiais de referência como artigos científicos, além de livros, normas técnicas e materiais de cursos da área.

Concomitantemente, foram identificados bancos de dados públicos com sinais provenientes de máquinas rotativas e selecionado um que melhor se adequa às necessidades deste trabalho. Nesse banco de sinais estão presentes anotações sobre o funcionamento normal do equipamento ou descrição e momento da falha.

Em seguida, ocorreu a fase de seleção, análise e implementação das técnicas de inteligência artificial. Um conjunto de sinais de treinamento foi selecionado a partir do banco de dados escolhido para treinar os sistemas de classificação de falha selecionados.

Após o treinamento dos classificadores, os modelos resultantes foram validados através de experimentos utilizando o restante do conjunto de sinais disponível.

A partir do processamento dos sinais de teste, técnicas estatísticas foram utilizadas para validação e comparação. Por fim, um *ranking* dos métodos por ordem de desempenho para essa aplicação é definido.

1.4 ESTRUTURA DO TRABALHO

O presente trabalho foi dividido em cinco capítulos, sendo o primeiro introdutório. O capítulo 2 – fundamentação teórica - trata dos principais conceitos necessários para o entendimento do trabalho desenvolvido, principalmente no que diz respeito à sua aplicação em manutenção preditiva através da análise de vibração em máquinas elétricas rotativas. Neste capítulo também é realizada a caracterização teórica dos cinco métodos utilizados para classificação, das métricas utilizadas para comparação de seus desempenhos e dos testes estatísticos.

O capítulo 3 trata sobre os materiais e métodos empregados. Para tanto, apresenta a descrição da base de dados utilizada, assim como o detalhamento das etapas de pré-processamento dos sinais analisados.

No capítulo 4 é realizada a análise dos resultados experimentais. Nele estão detalhados os resultados de eficiência de cada método aplicado através da matriz confusão, acurácia e sensibilidade, além da comparação

de desempenho entre os métodos implementados, através de análise estatística (testes ANOVA e t-Student).

Por fim, o capítulo 5 apresenta a conclusão do trabalho. Conta com comentários finais acerca do desenvolvimento da pesquisa, seus resultados e dificuldades encontradas, além de apresentar sugestões para futuros trabalhos na área.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os principais conceitos relacionados à utilização de métodos de inteligência artificial em aplicações de classificação de defeitos em máquinas rotativas.


A seção 2.1 trata da caracterização de máquinas rotativas e seus principais componentes mecânicos com vistas à análise de vibrações. As seções 2.2 e 2.3, descrevem os processos relacionados à manutenção preditiva e análise de vibração em máquinas, respectivamente. A seguir, na seção 2.4, três dos principais defeitos mecânicos são apresentados: desbalanceamento de rotores, desalinhamento dos eixos e defeitos em mancais de rolamento. As seções 2.5 e 2.6 discorrem acerca das técnicas de análise e processamento de sinais comumente utilizadas neste contexto, além de apresentar os cinco métodos de classificação automática analisados no presente trabalho. A seção 2.7 define as métricas adotadas para quantização do desempenho dos modelos, enquanto a seção 2.8 discorre sobre os testes estatísticos de hipótese utilizados na análise dos resultados. Por fim, a seção 2.9 apresenta uma lista das principais bibliotecas Python utilizadas na execução do trabalho.

2.1 MÁQUINAS ROTATIVAS

De maneira geral, o objetivo de uma máquina elétrica consiste na transformação de uma forma de energia primária em uma forma de energia secundária, sendo pelo menos uma delas de natureza elétrica (NEVES; GIL, 2000). Com isso, as máquinas elétricas rotativas são caracterizadas pela realização de conversões eletromecânicas, isto é, convertem movimento em eletricidade, no caso dos geradores elétricos, ou eletricidade em movimento, no caso dos motores elétricos.

Basicamente, do ponto de vista construtivo, as máquinas elétricas rotativas são constituídas por um elemento móvel (rotor), montado sobre um eixo, que normalmente gira no interior de um elemento fixo coaxial (estator). A Figura 2 mostra tais estruturas em um motor de corrente contínua (dc).

Figura 2 - Visão em corte do estator, rotor e eixo em um motor elétrico de corrente contínua.



Fonte: Adaptado de FITZGERALD; KINGSLEY JUNIOR; UMANS (2003) p.185


Além dos elementos citados anteriormente, outro tipo de estrutura importante para análise de vibrações em máquinas rotativas é o mancal, que pode ser dividido em mancal de deslizamento ou rolamento.

2.1.1 Mancais de deslizamento e rolamento

Os mancais são os elementos estruturais responsáveis pela sustentação do eixo da máquina. Para tal, acabam tendo de suportar todos os esforços mecânicos das forças que atuam sobre a estrutura.

Na área de geração, os mancais mais utilizados são os de deslizamento, visto que são capazes de suportar grande capacidade de carga (MATSUO, 2017). A Figura 3 ilustra um mancal desse tipo.


Figura 3 - Mancal de deslizamento.



Fonte: LÓPEZ (2014) p.8

Por outro lado, os mancais de rolamento são utilizados quando a máquina apresenta maiores velocidades de rotação, pois os rolamentos acabam por diminuir as perdas de energia por consequência do atrito (LÓPEZ, 2014). Um mancal de rolamento, apresentado na Figura 4, geralmente é constituído por dois anéis concêntricos, que contam com elementos rolantes como esferas e roletes.

Figura 4 - Mancal de rolamento



Fonte: LÓPEZ (2014) p.8

O mancal de rolamento é particularmente importante para este trabalho, visto que os dados de vibração analisados se originaram de uma máquina elétrica que conta com esse tipo de estrutura.

2.2 MANUTENÇÃO PREDITIVA

No contexto da engenharia de manutenção, destacam-se três filosofias principais para gestão de ativos: corretiva, preventiva e preditiva (MATSUO, 2017).

A manutenção corretiva apresenta menor complexidade de execução, atuando de forma reativa após o equipamento apresentar a falha. Contudo, esta abordagem se mostra ineficiente e dispendiosa no longo prazo, pois não apresenta possibilidade de planejamento para as equipes de manutenção (FREITAS, 2012).

Por outro lado, a manutenção preventiva se baseia em aplicar as ações de manutenção no equipamento antes de uma parada indevida, normalmente de forma periódica. A implementação dessa filosofia acaba por ampliar o tempo de vida útil da máquina, pois as falhas são mitigadas antes que ocorram. Todavia, por atuar com base em períodos de tempo de operação e não na condição do ativo, este tipo de manutenção pode resultar em paradas desnecessárias da máquina, diminuindo sua disponibilidade. Outro problema nesse tipo de abordagem é que qualquer intervenção no equipamento (desmontagem e montagem, por exemplo)

pode resultar na inserção de novos problemas de difícil detecção (MATSUO, 2017).

Apesar de historicamente já terem sido aplicadas na área de geração de energia, as filosofias de manutenção citadas podem não ser consideradas as mais adequadas para gestão de ativos valiosos como geradores e turbinas de energia elétrica, que demandam alta disponibilidade e confiabilidade (LÓPEZ, 2014). Assim, a manutenção preditiva apresenta-se como uma opção eficaz neste contexto, pois baseia-se na condição da máquina para otimizar o planejamento das ações de manutenção. Tem como objetivo, portanto, estender ao máximo o tempo de funcionamento do equipamento, atuando na iminência da falha (MATSUO, 2017).

A adoção cada vez maior deste tipo de filosofia de manutenção tornou-se possível devido à popularização e barateamento dos sistemas digitais de monitoração (SPANER, 2009). Segundo aponta Garcia (2005), a aplicação sistemática de programas de monitoração de vibrações em máquinas rotativas pode resultar, em grandes plantas, um retorno de dez a cinquenta vezes o montante investido no primeiro ano de operação.

2.3 ANÁLISE DE VIBRAÇÃO EM MÁQUINAS ROTATIVAS

A vibração pode ser definida como uma oscilação de um corpo em torno de uma posição de referência. Esse movimento em uma máquina é a resposta às forças dinâmicas que a excitam, e frequentemente é um processo destrutivo, ocasionando falhas nos elementos de máquinas por fadiga, como trincas, falhas por rupturas, dentre outros (MATSUO, 2017).

Assim, a análise de vibrações em máquinas rotativas desponta como uma das principais ferramentas para levantamento da condição de “saúde” de uma máquina, sendo esse conhecimento essencial para aplicação dos processos de manutenção preditiva. A norma ISO 13373-1 (INTERNATIONAL STANDART, 2002) descreve os aspectos relacionados ao monitoramento dos níveis de vibração em ativos, como os tipos de sensores utilizados, locais de medição e técnicas de análise dos sinais coletados. Essa abordagem de monitoramento de vibrações relacionada com a condição da máquina foi pela primeira vez reconhecida por Rathbone em 1939, em seu artigo *Vibration Tolerance*, conforme Randall aponta em seu livro *Vibration-Based Condition Monitoring* (RANDALL, 2011).

Para aplicação desse tipo de análise na área de geração de energia, os tipos de sensores mais difundidos são os acelerômetros e sensores de proximidade indutivos (MATSUO, 2017). Como os sinais de vibração

analisados neste trabalho são provenientes de acelerômetros, é conveniente caracterizá-los.

2.3.1 Acelerômetro Piezoeletrico

Um acelerômetro é um equipamento sísmico que gera um sinal de saída proporcional à aceleração vibracional mecânica do corpo analisado, sendo instalado, geralmente, em uma das estruturas estacionárias (não-girantes) da máquina rotativa (INTERNATIONAL STANDART, 2002). Um exemplo real desse tipo de sensor pode ser observado na Figura 5.


Figura 5 - Exemplo de acelerômetro piezoeletrico.



Fonte: MATSUO (2017) p.64

Um dos modelos mais comuns de acelerômetro é o piezoeletrico, cujo esquemático de funcionamento encontra-se ilustrado na Figura 6. Basicamente, uma lâmina de material piezoeletrico encontra-se dentro de uma caixa metálica e suporta o peso de uma massa também metálica. Enquanto o sistema estiver em repouso (sem sofrer vibração), a compressão resultante do peso suportado pela lâmina piezoeletrica acarretará em um determinado nível de tensão na saída do sensor. No caso da caixa sofrer uma aceleração para cima/baixo, a intensidade da compressão aumenta/diminui e a tensão de saída responderá de forma proporcional ao nível da vibração sofrida (LÓPEZ, 2014).

Figura 6 - Esquema de funcionamento de um acelerômetro.



Fonte: LÓPEZ (2014) p.13


2.4 PRINCIPAIS DEFEITOS MECÂNICOS EM MÁQUINAS

A norma ISO 13373-1 (INTERNATIONAL STANDART, 2002) evidencia diversos tipos de defeitos possíveis em máquinas rotativas, tais como: instabilidade, roçamento, ressonâncias, folgas mecânicas, falhas em correias de acionamento, componentes frouxos, entre outros. Contudo, considerando o escopo deste trabalho e a base de sinais analisada, destacam-se nesta seção três das principais falhas mecânicas encontradas: desbalanceamento, desalinhamento e defeito em mancais.

2.4.1 Desbalanceamento de rotores

Conforme cita Matsuo (2017), a vibração resultante do desbalanceamento de rotores talvez seja o problema mais comum encontrado em máquinas rotativas. Tal defeito é gerado pela distribuição irregular de massa em torno do eixo de rotação do rotor, ocasionando uma discrepância entre esse eixo e o eixo principal de inércia, conforme esquematizado na Figura 7.

Figura 7 - Discrepância entre o eixo de simetria e o eixo de rotação.

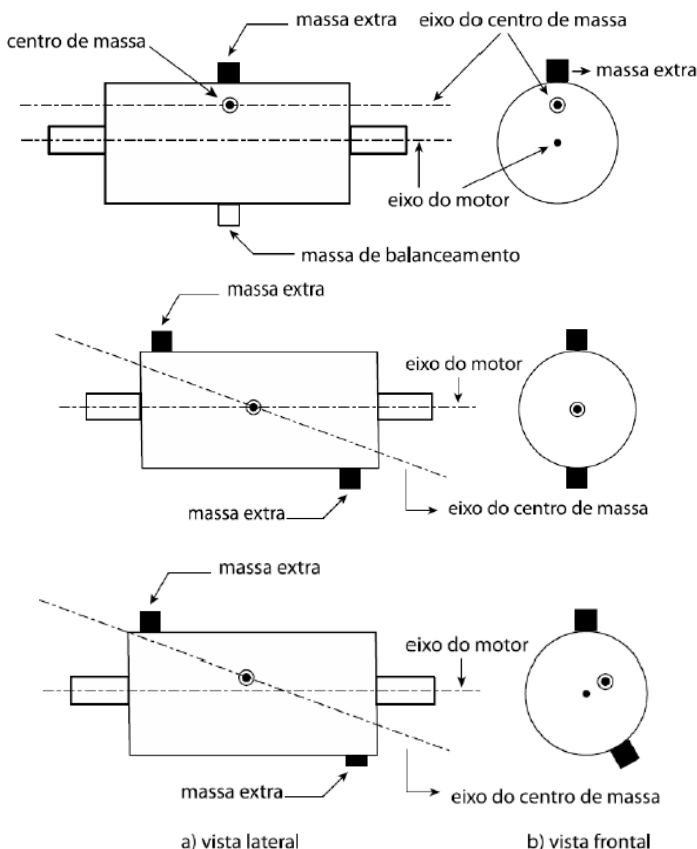


Fonte: LÓPEZ (2014) p.15

Dentre as consequências desse tipo de defeito destacam-se o sobrecarregamento dos mancais do sistema, diminuição da vida útil dos mancais, aumento de ruído audível e das perdas de potência, entre outras (BLOCH e GEITNER, 2005).

Por fim, ainda é possível classificar o problema de desbalanceamento em três tipos distintos, que se diferenciam em função da posição relativa entre os eixos de inércia e rotação da máquina. São eles: desbalanceamento estático (quando os eixos são paralelos entre si), acoplado (quando ambos se interceptam no centro de massa do rotor) e dinâmico, quando não há interceptação entre os eixos. A Figura 8 ilustra as três situações.

Figura 8 - Tipos de desbalanceamento (em ordem): estático, acoplado e dinâmico.




Fonte: Adaptado de MATSUO (2017)

2.4.2 Desalinhamento de eixos

Outro defeito mecânico comum presente em máquinas rotativas é o desalinhamento entre os eixos da máquina primária (ex: turbina hidráulica, térmica) e o eixo da carga (ex: rotor do gerador síncrono), ambos suportados por mancais. Esse problema pode ser provocado por fundações irregulares ou falhas no acoplamento dos equipamentos e, assim como o desbalanceamento, também pode ser dividido em três categorias: angular (eixos das máquinas apresentam um ângulo β entre

si), paralelo (eixos deslocados de forma paralela) ou combinado (combinação dos casos anteriores). A Figura 9 apresenta os três casos.

Figura 9 - Tipos de desalinhamento: (a) paralelo, (b) angular e (c) combinado.



Fonte: Adaptado de FERRAZ (2013)


Novamente, as consequências desse tipo de falha vão desde o aumento de consumo de energia a vibrações indesejadas. Pode ocorrer também um aumento de temperatura nos mancais e no acoplamento da máquina (SZYMON; PIETA, 2011).

2.4.3 Defeitos em mancais de rolamento

Os defeitos em mancais de rolamento evoluem de forma lenta e costumam apresentar características com bastante antecedência da falha final. No que diz respeito às suas origens, podem ser ocasionados devido a degradação de uma das partes que compõem sua estrutura, conforme apresentado na Figura 10.

Assim como já mencionado, os mancais são responsáveis por sustentar os diversos esforços mecânicos presentes e são, portanto, componentes críticos. Além disso, considera-se que por volta de 40% das falhas em máquinas se originam de problemas nesse tipo de estrutura (BONALDI, 2005). Riscos nas pistas, roletes ou esferas, trincas, corrosão e erosão estão entre as consequências desse tipo de defeito, que pode, em último caso, ocasionar a ruptura dos componentes e levar a falhas catastróficas do ativo.

Figura 10 - Elementos de um mancal de rolamento.



Fonte: LÓPEZ (2014) p.15

2.5 TÉCNICAS DE ANÁLISE PARA IDENTIFICAÇÃO DE DEFEITOS

No contexto da manutenção preditiva baseada em monitoração dos níveis de vibração, diversas técnicas de análise e processamento de sinais são empregadas. Assim, esta seção tem por objetivo apresentar as técnicas utilizadas durante a execução do trabalho, enfatizando a análise no domínio da frequência e sua relação com os tipos de defeitos mecânicos discutidos anteriormente.

2.5.1 Análise no domínio do tempo

As técnicas de análise no domínio tempo representam uma abordagem natural para os problemas de vibração, visto que o sensoriamento e obtenção dos sinais, na maioria das vezes, se dá através do processo de amostragem no decorrer do tempo.


Contudo, o elevado nível de conhecimento (e muitas vezes, complexidade computacional) exigido para extração de informações úteis sobre a condição da máquina utilizando somente o ferramental no domínio do tempo faz com que sejam preferidas outras técnicas, como a análise dos sinais no domínio da frequência (BONALDI, 2005).

O escopo deste trabalho não abrange a utilização de técnicas no domínio tempo para a classificação dos defeitos em máquinas rotativas. Como exemplos de técnicas no domínio tempo, podem ser citadas a análise do nível global de vibração, fator de crista e curtose (MATSUO, 2017).

2.5.2 Análise no domínio da frequência

A avaliação do espectro de frequência para análise de vibração é uma das técnicas mais conhecidas e utilizadas (MATSUO, 2017). Conforme denotado anteriormente, os sinais amostrados no domínio do tempo podem ser representados através de uma soma de senóides com frequências distintas e diferentes fases e amplitudes, vide Figura 11. Assim, a mudança do domínio do tempo para frequência se dá, entre outras formas, através da aplicação da ferramenta matemática Transformada de Fourier.

Figura 11 - Representação de um mesmo sinal no domínio do (1) tempo e (2) frequência.



Nota: X – Tempo; Y – Amplitude/Magnitude; Z - Frequência


Fonte: INTERNATIONAL STANDART (2016) p.2

Considerando que todo o processamento dos sinais de vibração é realizado de forma digital, as ferramentas utilizadas são a transformada discreta de Fourier (DFT - *Discrete Fourier Transform*) e sua forma otimizada, a transformada rápida de Fourier (FFT - *Fast Fourier Transform*). Detalhes sobre a implementação e uso destas ferramentas podem ser encontradas na literatura (LATHI, 2007) (PYTHON SOFTWARE FOUNDATION, 2018).

Por fim, se faz necessário enfatizar a relação entre as características específicas dos tipos de defeitos mecânicos apresentados com o comportamento dos sinais de vibração no domínio da frequência. Tal

correspondência é essencial para que seja possível justificar a utilização dos espectros dos sinais processados para classificação posterior de suas falhas. Como exemplo, para o problema de desbalanceamento ilustrado na Figura 12, pode-se observar o aumento da amplitude do sinal do acelerômetro na frequência de rotação da máquina, quando comparada com um equipamento sem este defeito.

Figura 12 - Comportamento do espectro de sinal de vibração na presença de defeito de desbalanceamento.




Fonte: Adaptado de LÓPEZ (2014) p.22

Já para o desalinhamento angular e paralelo, os espectros apresentam assinaturas distintas, conforme visto na Figura 13. Em seu trabalho, Matsuo (2017) destaca as principais frequências a serem observadas para cada tipo de defeito analisado, conforme apontado na Tabela 1, sempre considerando como referência a frequência de rotação do eixo da máquina.

Os defeitos relacionados aos mancais de rolamento são mais complexos e exigem ferramentas de análise mais sofisticadas, como o cepstrum e a detecção de envelope do sinal de ressonância de alta frequência (HFRT), cuja explicitação foge do escopo desse trabalho (LÓPEZ, 2014).

Figura 13 - Espectro proveniente de máquinas com (a) Desalinhamento Angular e (b) Desalinhamento Paralelo.



Fonte: LÓPEZ (2014) p.24

Tabela 1 - Relação dos defeitos e frequências características.

| Defeito | Frequências de vibração predominantes | Sentido | Comentários |
|----------------------------------|---------------------------------------|----------------|---|
| Desbalanceamento estático | 1× Freq de rotação | Radial | Medições nos mancais estão em fase. |
| Desbalanceamento acoplado | 1× Freq de rotação | Radial | Medições nos mancais estão defasadas em 180°. |
| Desbalanceamento dinâmico | 1× Freq de rotação | Radial | Medições nos mancais estão defasadas em ângulos entre 0° e 180° |
| Desalinhamento angular | 1×, 2× Freq de rotação | Axial e Radial | |
| Desalinhamento paralelo | 1×, 2× e múltiplos da Freq de rotação | Axial e Radial | 2× Freq de rotação; tende a ser maior que a fundamental. |

Fonte: MATSUO (2017).

2.6 MÉTODOS PARA CLASSIFICAÇÃO AUTOMÁTICA DE DEFEITOS

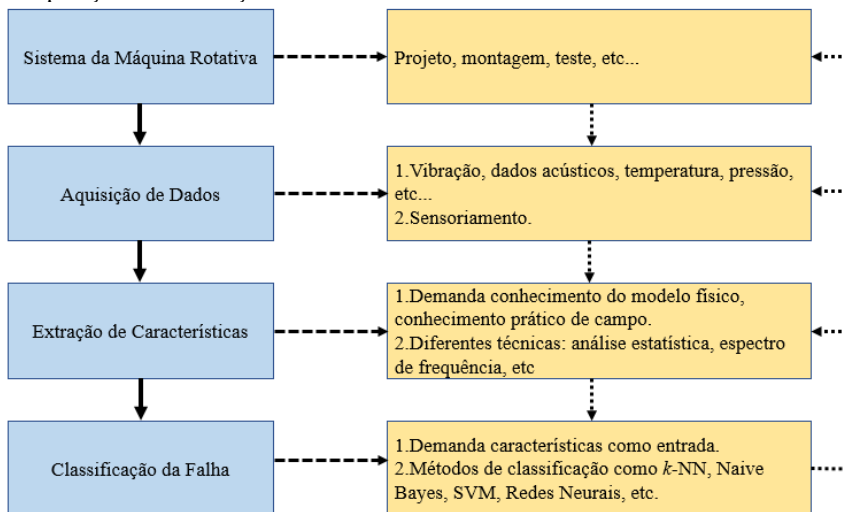
Segundo apontado na norma ISO 13379-2 (INTERNATIONAL STANDART, 2015), duas estratégias principais podem ser empregadas para o diagnóstico de defeitos em uma máquina: uma baseada em conhecimento sobre a física do equipamento (*knowledge-based*) e outra baseada em dados históricos de sinais coletados da máquina (*data-driven*). O alto nível de especialização exigido dos profissionais que trabalham com a primeira estratégia em contrapartida à popularização cada vez maior de sistemas de monitoramento digitais e o consequente aumento da base de dados disponível para análise, torna o emprego de soluções baseadas na segunda estratégia cada vez mais atrativo para a indústria.

No que diz respeito ao diagnóstico de falhas em uma máquina, estão atrelados três objetivos principais: determinar a condição atual do equipamento (normal ou não), identificar o defeito incipiente e suas causas, e prever a tendência com a qual o defeito pode se desenvolver (LIU et al., 2018). Com isso, pode-se caracterizar a análise de diagnóstico, em sua essência, como um problema de reconhecimento de padrões aplicado ao contexto de máquinas rotativas. Apresenta-se, portanto, a possibilidade do uso de técnicas de inteligência artificial.

Devido à não-trivialidade na análise de falhas em máquinas, o reconhecimento de padrões de defeitos pode apresentar uma alta complexidade para ser realizado diretamente. Assim, um sistema típico, conforme representado na Figura 14, apresenta duas etapas principais:

- Pré-processamento de dados, voltado à extração de características, com o objetivo de transformar os padrões de entrada do sistema para que possam ser representados na forma de vetores de características de baixa dimensão (*feature vector*), com o intuito de diminuir a complexidade computacional e o tempo de treinamento.
- Classificação, onde o vetor de características é utilizado como entrada para os algoritmos de inteligência artificial.

Figura 14 - Estrutura para diagnóstico de falhas utilizado na área de engenharia de operação e manutenção.



Fonte: Adaptado de LIU et al. (2018) p.44

Liu et al. (2018) e Elforjani e Shanbr (2018) evidenciam que classificadores e métodos de aprendizado estatístico figuram entre os mais usados em diagnóstico de defeitos em máquinas rotativas, devido à sua robustez e capacidade de adaptação. Assim, destacam-se cinco métodos de inteligência artificial, considerados na execução deste trabalho e descritos brevemente nas próximas subseções.

2.6.1 Regressão Logística

O principal objetivo da análise de um problema de classificação automática baseada em aprendizado supervisionado de máquina é a obtenção de uma função $h : X \rightarrow Y$, sendo X o conjunto de características de um vetor de entrada e Y o rótulo da classe a ser encontrado.¹

Neste contexto, a regressão logística apresenta-se como um método de classificação binária, capaz de retornar um $h(x)$ que prediga se os dados de entrada fazem parte de uma determinada classe ou não. Também é possível utilizar o método para casos nos quais o classificador

¹ O seguinte sistema de representação será utilizado para identificar cada tipo de variável: matrizes são letras maiúsculas em negrito, vetores são letras minúsculas em negrito, variáveis e constantes escalares são minúsculas em itálico e conjuntos são letras maiúsculas.

tenha de lidar com mais de duas categorias, como é o caso deste trabalho. Para tal, utiliza-se a estratégia conhecida como um-contra-todos, onde o classificador é treinado para a primeira classe e usa como contraexemplo todas as outras, repetindo o processo para todo o conjunto de classes (LÓPEZ,2014).

Basicamente, a regressão logística retorna a probabilidade estimada de uma dada saída (\hat{y}) para uma determinada entrada (x). Assim, se temos \hat{y} como saída prevista:

$$y = P(y=1 | x), \text{ com } 0 \leq y \leq 1 \quad (1)$$


$$y = \sigma(\mathbf{w}^T \mathbf{x} + b) \quad (2)$$

em que $x = \mathbf{w}^T \mathbf{x} + b$; $\mathbf{w} = [w_1 \ w_2 \ \dots \ w_N]^T$ é um vetor coluna composto por N coeficientes; $\mathbf{x} = [x_1 \ x_2 \ \dots \ x_N]^T$ é um vetor coluna com N informações de entrada (vetor de características); b é uma constante pré-definida; e a função $\sigma(z)$ é a função Sigmóide.

A função sigmóide, muito utilizada neste tipo de aplicação, tem seu gráfico apresentado na Figura 15. Assim, basta aplicar um critério de decisão sobre \hat{y} para prever a classe resultante (classe 1 se $\hat{y} > 0,5$, por exemplo).

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (3)$$

Figura 15 - Gráfico da função Sigmóide.



Fonte: Elaborado pelo autor.


Os parâmetros \mathbf{w} e b em (2) são definidos ao final da fase de treinamento através de um processo de otimização. Basicamente, é definida uma função custo $J(\mathbf{w}, b, \mathbf{X})$ (veja Eq. (4)) que deve ser minimizada. Segundo López (2014), existem outras funções custo que podem ser escolhidas, mas a função custo da equação (4) pode ser derivada usando o princípio de estimativa por máxima verossimilhança, que é um método estatístico para encontrar eficientemente os parâmetros \mathbf{w} e b que melhor ajustam os dados ao modelo. Esta função também possui a propriedade de ser convexa, o que facilita a convergência para seu mínimo global.

$$J(\mathbf{w}, b, \mathbf{X}) = -\frac{1}{M} \sum_{i=1}^M [y_i \log y_i + (1 - y_i) \log(1 - y_i)] \quad (4)$$

em que $J(\mathbf{w}, b, \mathbf{X})$ é a função custo, $\mathbf{X} = [\mathbf{x}_1 \mathbf{x}_2 \dots \mathbf{x}_M]$ é o conjunto de treinamento, e M é o número de exemplos no conjunto de treinamento.

Ainda é interessante ressaltar que este tipo de classificador permite a criação de fronteiras de decisão lineares ou polinômicas, que ditam como as classes serão separadas (LÓPEZ, 2014), conforme consta na Figura 16.

Figura 16 - Regressão Logística com fronteiras de decisão linear e polinômica.



Fonte: LÓPEZ (2014) p.66

Por fim, comenta-se que diversos aspectos sobre os detalhes e teoria da regressão logística não foram aqui abordados pois fogem do escopo deste trabalho. Mais informações sobre tópicos como regularização, descrição do método de gradiente descendente e implementações computacionais podem ser encontradas em (DREISEITL; OHNO-MACHADO, 2002).


2.6.2 k -NN

O método *k-Nearest Neighbour* (k -NN) considera, basicamente, que instâncias dentro de um conjunto de dados geralmente estarão mais próximas de outras instâncias com propriedades similares.

Considera-se, por exemplo, um conjunto de dados utilizados para treinamento de um modelo caracterizado por $T = \{ (x_1, y_1), (x_2, y_2), \dots, (x_N, y_N) \}$, com \mathbf{x}_i representando o vetor de características das instâncias não rotuladas e \mathbf{y}_i os rótulos para $i = 1, \dots, N$. Assim, para a classificação de uma nova instância com rótulo desconhecido que tenha \mathbf{x} por vetor de características, o método k -NN realiza a procura das k^2 instâncias em T mais próximas de \mathbf{x} , baseando-se para tal em uma métrica de distância (distância euclidiana, por exemplo). Com isso, o rótulo de \mathbf{x} é definido de acordo com o rótulo que represente o maior número de “vizinhos” entre os k vizinhos observados (RASCHKA; MIRJALILI, 2017).

A Figura 17 apresenta o diagrama do método k -NN empregado em um caso de classificação. Existem dois rótulos (positivo e negativo) e os círculos de diferentes raios indicam a métrica para cálculo de distância adotada. Assim, com a definição do número k de vizinhos mais próximos a serem analisados e com a regra de decisão definida (sendo, no caso, o rótulo que aparece com maior frequência), é possível classificar a amostra tomada.

Figura 17 - Representação do diagrama k -NN. Dependendo do número k selecionado, a amostra de teste (*Test sample*) pode ser classificada como positiva ($k = 1$ e $k = 5$) ou negativa ($k = 3$)



Fonte: LIU et al. (2018) p.3


² Constante inteira positiva, definida pelo usuário, necessária para execução do método.

2.6.3 SVM

Trata-se de um método de aprendizagem computacional para classificação de amostras pequenas. O método funciona através do mapeamento dos dados para um espaço de parâmetros de maior dimensão, possibilitando a categorização dos pontos (mesmo quando os dados não forem linearmente separáveis). Um separador entre as categorias é encontrado e, então, os dados são transformados de tal forma a possibilitar o uso de um hiperplano como separador. Assim, futuros pontos amostrados podem ser classificados utilizando o modelo treinado (LIU et al., 2018).

Um exemplo visual é apresentado na Figura 18, onde pontos espalhados pertencem a uma de duas possíveis categorias.


Figura 18 - Conjunto de dados inicial.



Fonte: IBM (2018)

As categorias apresentadas podem ser separadas através de uma curva, como mostra a Figura 19.


Figura 19 - Dados com separador adicionado.



Fonte: IBM (2018)

Por fim, o limite entre as duas categorias pode ser definido linearmente após a transformação, através de um hiperplano (Figura 20).

Figura 20 - Dados transformados.



Fonte: IBM (2018)

A função matemática utilizada para a transformação é conhecida como função *kernel*, e pode ser de caráter linear, polinomial, entre outras.

2.6.4 Naive Bayes

Naive Bayes é um método de aprendizado de máquina usado para classificação que considera as variáveis de entrada (elementos do vetor de características, por exemplo) como independentes. Por esse motivo é tido como ingênuo (*naive* em inglês), visto que, na maioria dos casos, a suposição de independência das características de uma instância é falsa (RASCHKA, 2014).

O método tem por base o teorema de Bayes, que trata sobre probabilidade condicional. Isto é, qual a probabilidade de o evento A ocorrer, dado o evento B (MONTGOMERY; RUNGER; HUBELE, 2004). O teorema pode ser resumido pela seguinte fórmula:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad (5)$$

Lê-se: a probabilidade do evento A ocorrer dado que o evento B ocorra é igual probabilidade do evento B ocorrer dado o evento A vezes a probabilidade do evento A sobre a probabilidade do evento B.

Essa mesma lógica pode ser utilizada para o cálculo das probabilidades necessárias para problemas de classificação. Para tal, basta substituir um dos argumentos da fórmula pela classe a ser calculada.

$$P(\text{classe}|\text{B}) = \frac{P(\text{B} | \text{classe})P(\text{classe})}{P(\text{B})} \quad (6)$$

Lê-se: a probabilidade de pertencer à classe escolhida, dado o atributo B, é igual à probabilidade do atributo B ocorrer dado que ele pertence a classe escolhida vezes a probabilidade de ocorrer a classe sobre a probabilidade do evento B.

Para determinar a classe mais provável da nova instância (e realizar a predição, objetivo de um problema de classificação), calcula-se a probabilidade de todas as possíveis classes e, no fim, escolhe-se a classe com a maior probabilidade como rótulo da nova instância.

Em termos estatísticos, isso é o mesmo que maximizar a $P(\text{classe} | x_1 \dots x_N)$, sendo x_i um elemento pertencente ao vetor de N características de uma instância. Para tanto, deve-se maximizar o valor do numerador $P(x_1 \dots x_N | \text{classe}) \times P(\text{classe})$ e minimizar o valor do denominador $P(x_1 \dots x_N)$. Como o denominador $P(x_1 \dots x_N)$ é uma constante, pois não depende da variável classe que se está procurando, pode-se anulá-lo no teorema de Bayes, resultando na fórmula a seguir, na qual se procura a classe que maximize o valor do termo $P(\text{classe} | x_1 \dots x_N) = P(x_1 \dots x_N | \text{classe}) \times P(\text{classe})$:

$$\text{argmax } P(\text{classe} | x_1 \dots x_N) = \text{argmax } P(x_1 \dots x_N | \text{classe}) \times P(\text{classe}) \quad (7)$$

A suposição “ingênua” que o classificador naïve-Bayes faz é que todos os atributos $x_1 \dots x_N$ da instância que se quer classificar são independentes. Sendo assim, o cálculo do valor do termo $P(x_1 \dots x_N | \text{classe})$ reduz-se ao cálculo de $P(x_1 | \text{classe}) \times \dots \times P(x_N | \text{classe})$. Assim, a fórmula final utilizada pelo classificador é:


$$\text{argmax } P(\text{classe} | x_1 \dots x_N) = \text{argmax } \prod_{i=1}^N P(x_i | \text{classe}) \times P(\text{classe}) \quad (8)$$

2.6.5 Redes Neurais Artificiais

Um dos métodos mais comuns atualmente (LIU et al., 2018), a rede neural artificial busca implementar uma solução de aprendizagem computacional através de estruturas que imitam o formato dos neurônios biológicos e suas conexões. É composta por três elementos principais: camada de entrada, camada oculta (*hidden layer*) e camada de saída. Estes elementos contam com várias unidades de processamento simples (neurônios). Os neurônios, por sua vez, são conectados por canais de comunicação que estão associados a determinado peso. As unidades fazem operações apenas sobre seus dados locais, que são entradas recebidas pelas suas conexões. O comportamento inteligente de uma rede neural artificial vem das interações entre os neurônios de suas camadas (GOODFELLOW; BENGIO; COURVILL, 2016).

A Figura 21 apresenta graficamente a estrutura (a) de um neurônio biológico e (b) de um modelo simples de Rede Neural Artificial.

Figura 21 - Neurônio biológico (a) e estrutura de uma Rede Neural Artificial (b)



Fonte: LIU et al. (2018) p. 4

Assim como o método de regressão logística, as redes neurais artificiais também tratam de um problema de otimização, onde se busca encontrar os pesos ideais entre os neurônios de cada camada para otimizar a relação entre o vetor de características de entrada e as previsões da camada de saída. Para tal, também é definida uma função custo a ser minimizada através da escolha ótima de seus parâmetros (GOODFELLOW; BENGIO; COURVILL, 2016).

O método *backpropagation* apresenta-se como um dos principais algoritmos para o treinamento de modelos de redes neurais, atuando de forma computacionalmente eficiente. Segundo Goodfellow, Bengio e

Courvill (2016), o algoritmo de *backpropagation* consiste basicamente em duas fases:

1. O passo para frente (*forward pass*), onde as entradas são passadas através da rede e as previsões de saída obtidas (essa etapa também é conhecida como fase de propagação).
2. O passo para trás (*backward pass*), onde calcula-se o gradiente da função custo na camada final (ou seja, camada de previsão) da rede e utiliza-se esse gradiente para aplicar recursivamente a regra da cadeia (*chain rule*) para atualizar os pesos na rede (etapa também conhecida como fase de atualização de pesos ou retro-propagação).

Com isso, esses passos podem ser executados repetidamente por um número fixo de iterações (1000, por exemplo) ou até que a função custo convirja para um valor mínimo (respeitando-se um delta mínimo entre cada iteração: 10^{-3} , por exemplo). Um maior detalhamento do algoritmo e suas aplicações pode ser encontrado em Suliman e Zhang (2015).

2.7 MÉTRICAS DE DESEMPENHO

Para que o cumprimento do objetivo principal deste trabalho seja possível, se faz necessária a escolha de métricas de avaliação utilizadas para quantificar o desempenho de cada classificador. Para tal, definem-se, nessa seção, três métricas comumente empregadas na análise de desempenho de classificadores: matriz confusão, acurácia e sensibilidade (RASCHKA; MIRJALILI, 2017).

A matriz confusão apresenta o desempenho de um método de classificação. Trata-se, basicamente, de uma matriz quadrada que expõe a contagem de verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos. A Figura 22 apresenta um diagrama com a disposição dos elementos da matriz, que pode ser explicada através do exemplo a seguir.

Supõe-se que existam as classes 0 e 1, representando o diagnóstico de uma máquina com defeito e uma máquina sem defeito, respectivamente. Assim, observando a Figura 22, cada posição (linha, coluna) na matriz representa:

- Posição (0,0): representa a quantidade correta de vezes que o classificador identificou máquinas com defeito (verdadeiro positivo);
- Posição (0,1): quando a máquina apresenta defeito, mas o classificador a diagnosticou como sem defeito (falso negativo);

- Posição (1,0): máquina sem defeito, mas diagnosticada como apresentando defeito (falso positivo);
- Posição (1,1): máquina sem defeito diagnosticada corretamente (verdadeiro negativo).


Figura 22 - Diagrama - matriz confusão.

| | | Classe - Predição | |
|--------------------------|---|--------------------------|---------------------|
| | | 0 | 1 |
| Classe - Objetivo | 0 | Verdadeiro Positivo | Falso Negativo |
| | 1 | Falso Positivo | Verdadeiro Negativo |

Fonte: Adaptado de RASCHKA; MIRJALILI (2017)

Para o caso de classificação com múltiplas categorias, se faz necessário converter a matriz que relaciona todas as classes para as matrizes confusão correspondentes a cada classe analisada, conforme aponta a Figura 23. Ressalta-se que a diagonal principal da matriz é essencial para cálculo da taxa de acerto nas classificações. As subseções 4.2.1 a 4.2.5 apresentam as matrizes confusão dos cinco métodos utilizados.

Figura 23 - Cálculo dos elementos da matriz confusão para casos de múltiplas classes



Fonte: RASCHKA; MIRJALILI (2017)

Outra métrica utilizada para avaliação do desempenho geral de um classificador é a acurácia. Para um problema de classificação de múltiplas classes, a acurácia de um classificador é dada como a relação de todas as predições corretas ($\hat{y} = y$) pelo total de N amostras do conjunto analisado (SCIKIT-LEARN, 2018), de tal forma que:

$$Ac = 100 \frac{V_N + V_P}{V_N + V_P + F_N + F_P}, \quad (9)$$

em que V_N é o número de verdadeiros negativos; V_P é o número de verdadeiros positivos; F_P é o número de falsos positivos; e F_N é o número de falsos negativos.

Por fim, a última métrica analisada é a sensibilidade. A sensibilidade diz respeito à proporção de verdadeiros positivos, ou seja, a capacidade do sistema em prever corretamente a condição para casos que realmente a têm. Seu cálculo pode ser expresso através de:

$$Sensibilidade = 100 \frac{V_P}{V_P + F_N}, \quad (10)$$

em que V_P é o número de verdadeiros positivos e F_N é o número de falsos negativos.

2.8 TESTES ESTATÍSTICOS DE HIPÓTESE

Testes de hipótese, como o próprio nome indica, são aplicados quando se pretende verificar se uma determinada afirmação sobre a relação de um conjunto de amostras analisadas é verdadeira (MONTGOMERY; RUNGER; HUBELE, 2004). No caso deste trabalho, foi analisado se os diferentes métodos de classificação eram realmente distintos em relação à sua acurácia e sensibilidade ou se algum subconjunto deles poderia ser considerado semelhante em termos de performance (possuindo comportamento estatístico semelhante, apesar de diferirem em casos isolados). Neste contexto, apresentam-se dois testes de hipótese: teste ANOVA e teste t-Student.

Basicamente, o teste t-Student pode ser utilizado para avaliar se há diferença significativa entre as médias de duas amostras, enquanto que com o teste de análise de variância ANOVA, é possível analisar se um conjunto maior de amostras possui diferenças significativas entre suas médias. Denota-se a importância do cumprimento dos requisitos para utilização de tais testes, como a necessidade dos conjuntos de amostras seguirem uma distribuição normal e o número mínimo de dados para sua aplicação (IRSOY; YILDIZ; ALPAYDIN, 2012).

2.9 BIBLIOTECAS PYTHON

Todos os procedimentos implementados no pré-processamento dos dados, assim como a implementação dos diferentes métodos de inteligência artificial empregados no trabalho, foram executados utilizando a linguagem de programação Python e seus pacotes de bibliotecas. Essa linguagem foi escolhida pois conta com uma comunidade ativa de desenvolvedores na área de ciência e análise de dados, além de possuir caráter *open source* e vasta documentação disponível.

Segue uma breve relação das principais bibliotecas utilizadas neste projeto:

- *Numpy* e *Scipy*, bibliotecas com funções para computação científica. Contam com funções importantes já implementadas e validadas

(cálculo de FFT e testes estatísticos, por exemplo), além de serem otimizadas para trabalhos com vetores e matrizes de dados.

- *Pandas*, biblioteca de manipulação e análise de dados.
- *Matplotlib*, para criação de gráficos dos mais variados tipos.
- *Scikit-learn*, *Tensorflow* e *Keras*: contam com implementações dos métodos de inteligência artificial analisados neste trabalho.

Ressalta-se, portanto, a importância de contar com ferramentas eficazes de implementação computacional. Mais informações sobre a linguagem e suas funcionalidades podem ser encontradas em Python (2018).

3 MATERIAIS E MÉTODOS

Este capítulo tem por objetivo descrever os materiais e métodos utilizados durante a execução do trabalho. As próximas seções tratam de discutir as particularidades da base de dados escolhida para treinamento dos métodos de classificação, além de apresentar as estratégias adotadas para extração das características, pré-processamento dos dados e particularidades da implementação dos métodos analisados.

3.1 DESCRIÇÃO DA BASE DE DADOS UTILIZADA

Uma das etapas mais importantes para execução deste trabalho foi a escolha da base de dados a ser analisada, visto que toda a estratégia de treinamento e validação dos métodos de classificação automática depende de dados históricos coerentes.

Neste contexto, foram avaliadas algumas alternativas, como a *Case Western Reserve University Bearing Database* (CWRU, 2018) e a base de dados *Machinery Fault Database* - MAFAULDA (SMT, 2017). Foi escolhida a base apresentada por MAFAULDA (SMT, 2017). Trata-se de um conjunto de dados aquisitados em bancada de simulação do Laboratório de Sinais, Multimídia e Telecomunicações da Universidade Federal do Rio de Janeiro. Optou-se pela utilização dessa base por ela ser de uso livre, possuir documentação detalhada (LÓPEZ, 2014) e apresentar dados de seis condições da máquina (condição normal e cinco tipos de falha) já classificados. As subseções abaixo discutem mais aspectos sobre a MAFAULDA.

3.1.1 Configuração da aquisição de dados

Para aquisição dos dados, López (2014) descreve em seu trabalho o uso da bancada de simulação de falhas mecânicas *SpectraQuest*, que conta com as especificações listadas na Tabela 2.


Tabela 2 - Especificações da bancada experimental.

| | |
|--------------------------------|---|
| Motor | 1/4 CV DC |
| Faixa de velocidade | 700-3600 RPM |
| Massa do sistema | 22 kg |
| Eixo | Diâmetro: 16 mm Comprimento: 520 mm |
| Rotor | Diâmetro: 15,24 cm |
| Separação entre mancais | 390 mm |

Fonte: LÓPEZ (2014) p.28

Além do motor e mancais, a configuração dos testes conta ainda com um conjunto de sensores de vibração (acelerômetros, montados sobre os mancais nas três direções: axial, radial e tangencial), rotação (tacômetro) e sinal acústico (microfone) conforme representado na Figura 24.


Figura 24 - Bancada de simulação SpectraQuest e disposição dos sensores.



Fonte: Adaptado de LÓPEZ (2014)

Por fim, foram coletados dados de seis tipos de experimento: condição normal da máquina, dois casos de desalinhamento (vertical e horizontal, induzidos através de calços nos suportes dos mancais), desbalanceamento (induzido através da fixação de massa no rotor) e dois casos de falhas nos mancais de rolamento (através da inserção de mancal defeituoso na posição invertida e não invertida, como visto na Figura 25). Para todos os casos foram realizadas diversas coletas assumindo diferentes valores de rotação da máquina.

Figura 25 - Defeito no mancal de rolamento: (a) posição invertida (b) não invertida.



Fonte: LÓPEZ (2014) p.46

3.1.2 Organização da base de dados

A base de dados MAFAULDA está disponível para consulta (SMT, 2017) através do *download* de tabelas no formato “valores separados por vírgula” (csv – *comma separated values*). Cada arquivo corresponde a um experimento onde as colunas representam os diferentes dados de sensores utilizados:

- tacômetro;
- acelerômetro sobre o mancal na posição não invertida (*under-hang*) nas direções axial, radial e tangencial;
- acelerômetro sobre o mancal na posição invertida (*over-hang*) nas direções axial, radial e tangencial;
- microfone.

Cada sequência, relativa aos dados de vibração, foi gerada com uma taxa de amostragem de 50 kHz durante 5 segundos, totalizando 250 mil amostras. A Tabela 3 descreve o total de exemplos coletados para cada tipo de defeito simulado.

Tabela 3 - Número de casos coletados para cada tipo de defeito simulado.

| | |
|--|-------------|
| Normal | 49 |
| Desalinhamento horizontal | 197 |
| Desalinhamento vertical | 301 |
| Desbalanceamento | 333 |
| Mancal de rolamento posição não invertida | 558 |
| Mancal de rolamento posição não invertida | 513 |
| Total | 1951 |

Fonte: SMT (2018)

O objetivo final dos classificadores será prever à qual das seis categorias pertence uma nova amostra de entrada.

3.2 PRÉ-PROCESSAMENTO DE DADOS

Uma etapa essencial ao se empregar métodos de aprendizado de máquina é o pré-processamento de dados. Ela é responsável por manipular os dados originais de forma a otimizar seu emprego na etapa de treinamento e validação dos classificadores. Esta seção discute como o pré-processamento dos dados da base MAFAULDA foi implementado.

3.2.1 Extração das características

Conforme comentado anteriormente na Seção 2.6, a seleção de informações pertinentes contidas nos dados para a montagem de um vetor de características é muito importante no contexto da classificação automática, visto que permite diminuir a dimensão dos vetores de entrada e, por conseguinte, a complexidade e tempo de treinamento exigidos pelo método (LIU et al., 2018).

No caso da base de dados MAFAULDA, utilizar todos os dados disponíveis, sem nenhum tipo de pré-processamento, para a montagem do vetor de características resultaria no emprego de um vetor de entrada de dimensão 2 milhões (250 mil amostras coletadas dos 8 sensores).

Assim, adotou-se uma estratégia de pré-processamento dos dados originais baseada no trabalho de López (2014), que tem por fundamentação a relação já discutida entre as magnitudes das harmônicas da frequência de rotação da máquina e os diferentes tipos de defeitos mecânicos existentes, conforme apresentado na Tabela 1.

Basicamente, o vetor de características, definido na etapa de pré-processamento, é constituído por 19 informações (Tabela 4). A próxima subseção detalha os passos tomados para obtenção desse vetor nos casos de condição normal e defeituosa da máquina.

Tabela 4 - Sinais do vetor de características após pré-processamento.

| Nome | Descrição |
|------------------|---|
| R_f | Frequência de rotação do rotor |
| $ Rf_axial1 $ | Magnitude do espectro na frequência R_f do sinal do acelerômetro na direção axial no mancal 1 |
| $ 2Rf_axial1 $ | Magnitude do espectro na frequência $2R_f$ do sinal do acelerômetro na direção axial no mancal 1 |
| $ 3Rf_axial1 $ | Magnitude do espectro na frequência $3R_f$ do sinal do acelerômetro na direção axial no mancal 1 |
| $ Rf_radial1 $ | Magnitude do espectro na frequência R_f do sinal do acelerômetro na direção radial no mancal 1 |
| $ 2Rf_radial1 $ | Magnitude do espectro na frequência $2R_f$ do sinal do acelerômetro na direção radial no mancal 1 |
| $ 3Rf_radial1 $ | Magnitude do espectro na frequência $3R_f$ do sinal do acelerômetro na direção radial no mancal 1 |
| $ Rf_tg1 $ | Magnitude do espectro na frequência R_f do sinal do acelerômetro na direção tangencial no mancal 1 |
| $ 2Rf_tg1 $ | Magnitude do espectro na frequência $2R_f$ do sinal do acelerômetro na direção tangencial no mancal 1 |
| $ 3Rf_tg1 $ | Magnitude do espectro na frequência $3R_f$ do sinal do acelerômetro na direção tangencial no mancal 1 |
| $ Rf_axial2 $ | Magnitude do espectro na frequência R_f do sinal do acelerômetro na direção axial no mancal 2 |
| $ 2Rf_axial2 $ | Magnitude do espectro na frequência $2R_f$ do sinal do acelerômetro na direção axial no mancal 2 |
| $ 3Rf_axial2 $ | Magnitude do espectro na frequência $3R_f$ do sinal do acelerômetro na direção axial no mancal 2 |
| $ Rf_radial2 $ | Magnitude do espectro na frequência R_f do sinal do acelerômetro na direção radial no mancal 2 |
| $ 2Rf_radial2 $ | Magnitude do espectro na frequência $2R_f$ do sinal do acelerômetro na direção radial no mancal 2 |
| $ 3Rf_radial2 $ | Magnitude do espectro na frequência $3R_f$ do sinal do acelerômetro na direção radial no mancal 2 |
| $ Rf_tg2 $ | Magnitude do espectro na frequência R_f do sinal do acelerômetro na direção tangencial no mancal 2 |
| $ 2Rf_tg2 $ | Magnitude do espectro na frequência $2R_f$ do sinal do acelerômetro na direção tangencial no mancal 2 |
| $ 3Rf_tg2 $ | Magnitude do espectro na frequência $3R_f$ do sinal do acelerômetro na direção tangencial no mancal 2 |

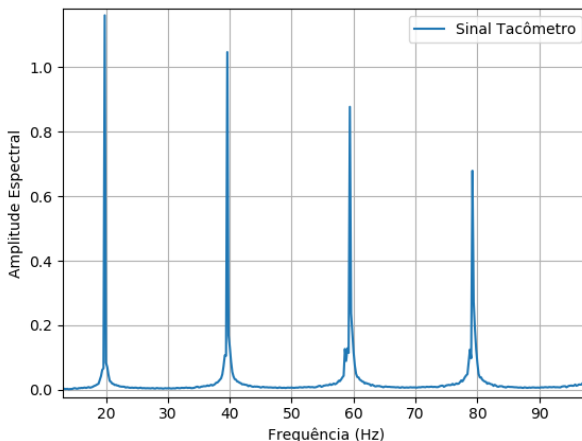
Fonte: Elaborado pelo autor.

3.2.2 Expansão do banco de dados para condições normais

Contrariamente a uma situação convencional de formação de um banco de dados de treinamento, a base de dados utilizada apresenta um número reduzido de casos de funcionamento normal do motor (49) em comparação às situações patológicas. Conforme analisado por Lópes (2014), treinar um modelo com poucos exemplos de uma determinada classe acaba por diminuir a taxa de acertos de suas classificações. A partir dessa observação foi implementado um procedimento para aumento artificial do número de casos associados ao funcionamento normal. Para tanto, os passos executados foram os seguintes.

- 1) Para cada sinal de funcionamento normal é calculada a frequência de rotação da máquina efetuando-se a operação de FFT no sinal do tacômetro e observando-se qual frequência apresenta a maior magnitude no espectro. A Figura 26 exibe um exemplo de espectro da máquina com rotação aproximada de 1200 rotações por minuto (RPM), equivalente a 20 Hz.

Figura 26 - Espectro do sinal do tacômetro da máquina girando a 1200 RPM.

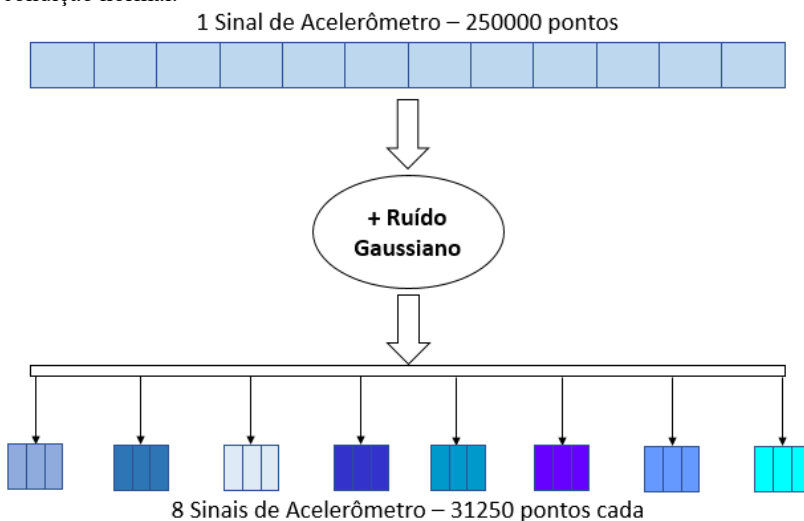


Fonte: Elaborado pelo autor.

- 2) Realiza-se um processo conhecido como *Data Augmentation*, ou seja, a partir de um determinado sinal composto por um número limitado de amostras é produzidos um conjunto de novos sinais diferentes. Neste caso específico, cada sinal proveniente dos

acelerômetros, originalmente contando com 250 mil pontos, é dividido em oito partes de 31250 pontos cada³. Em sequência, é somado um ruído gaussiano às amostras dos sensores, o que segundo Lópes (2014) também auxilia na otimização do processo de classificação. Segue uma representação visual desse procedimento na Figura 27.

Figura 27 - Processo de *Data Augmentation* dos sinais de vibração para a condição normal.



Fonte: Elaborado pelo autor.

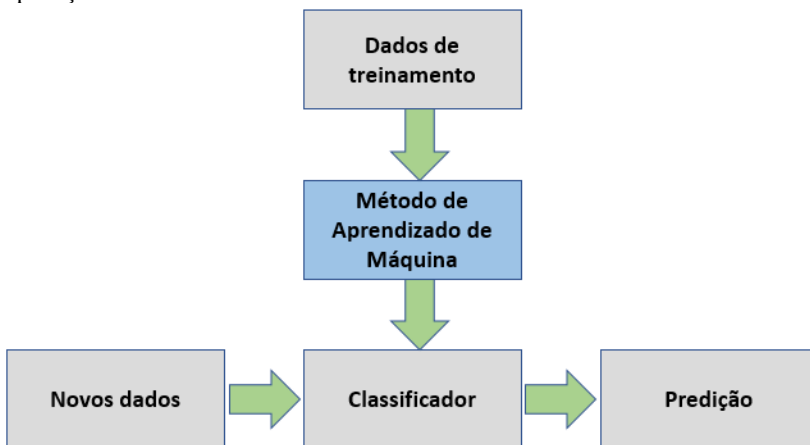
- 3) Encontra-se, para cada sinal de vibração, os valores de R_f , $2R_f$ e $3R_f$. Para tal, considerou-se a frequência de rotação já encontrada e uma janela de 10 Hz ao redor de R_f , $2R_f$ e $3R_f$ para definição dos maiores valores.
- 4) Por fim, após percorrer todos os 392 exemplos ($49 \text{ originais} \times 8$), um arquivo do tipo csv contendo os vetores de características de todos os casos normais foram gerados (matriz de dimensão 392×19).

³ Essa janela de dados utilizada compreende ao menos uma revolução completa da máquina e caracteriza prática recorrente no processamento e análise de vibrações em máquinas rotativas (SHENG, 2012)

3.3 PROCEDIMENTO PARA IMPLEMENTAÇÃO DE CLASSIFICADORES

Conforme apresenta a Figura 28, o procedimento padrão para a implementação de classificadores automáticos consiste primeiramente em uma etapa de treinamento, onde cada método é aplicado com dados de entrada já classificados (RASCHKA, 2014). Com isso, é gerado como saída um modelo que deverá ser testado com novos dados, diferentes dos utilizados durante a fase de treinamento, para que então suas previsões sejam avaliadas através das métricas de desempenho especificadas.

Figura 28 - Diagrama simplificado do procedimento padrão para treinamento e aplicação de classificadores automáticos.



Fonte: Adaptado de RASCHKA (2014)

Assim, essa seção tem por objetivo discorrer sobre a implementação prática desses métodos, através das bibliotecas utilizadas da linguagem Python e o processo de decisão para a escolha de alguns de seus parâmetros internos.

3.3.1 Classificador Regressão Logística

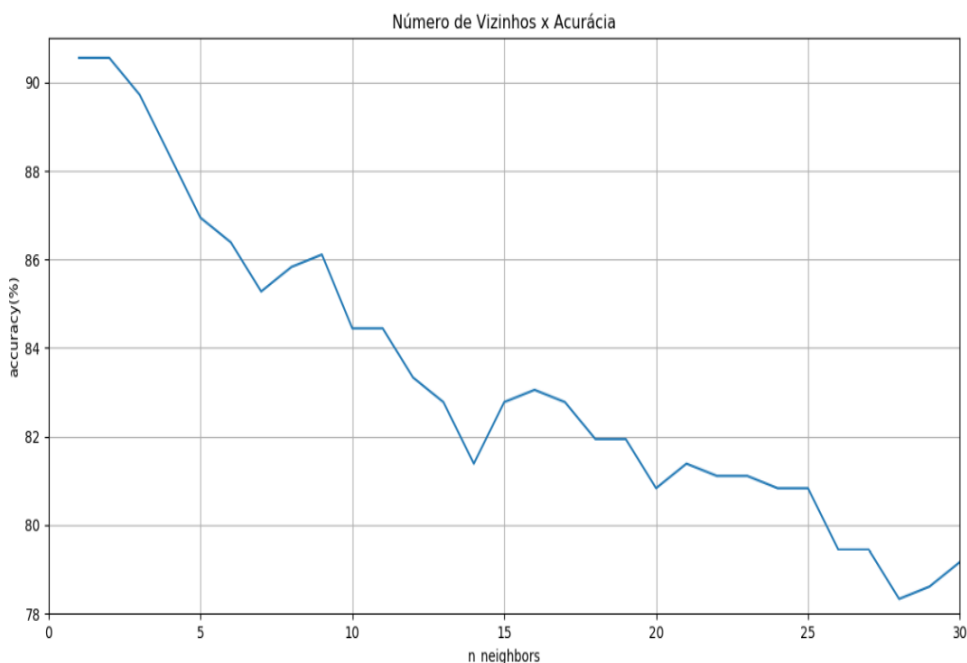
Foi utilizada a biblioteca *linear_model* do *scikit-learn* com configurações padrão para o treinamento e testes do método de regressão logística. Os novecentos casos utilizados no procedimento contaram com exemplos de cada tipo de defeito em igual quantidade e foram divididos em 80% para dados de treinamento e 20% para testes.

3.3.2 Classificador k -NN

No caso do classificador k -NN, um parâmetro importante a ser definido é o número k . Este parâmetro representa a quantidade de casos “vizinhos” (próximos em distância) a um novo ponto que serão consideradas para decidir a qual classe ele pertence.

Para auxiliar na escolha de k , realizou-se uma série de testes nos quais o valor do parâmetro foi variado. A Figura 29 ilustra o resultado da relação entre diferentes escolhas de k e a acurácia do modelo observada. Assim, optou-se pela utilização de $k = 2$.

Figura 29 - Relação desempenho (acurácia) em função do número de “vizinhos” considerados para aplicação do método k -NN.



Fonte: Elaborado pelo autor

3.3.3 Classificador SVM

A aplicação do método SVM foi executada através do uso da biblioteca *sklearn.svm.SVC*, adotando-se as configurações padrão e *kernel* linear.


3.3.4 Classificador Naive Bayes

Para a implementação do classificador Naive Bayes foram utilizadas as configurações padrão da biblioteca *sklearn.naive_bayes* no conjunto de treinamento e teste dos dados.

3.3.5 Classificador Rede Neural Artificial

A topologia escolhida para o classificador rede neural artificial foi baseado no trabalho de López (2014). Trata-se de uma rede de camada oculta única, como apresentado na Figura 30. Para a aplicação neste trabalho, o vetor de entradas é composto pelas dezenove características obtidas na etapa de pré-processamento. Já as saídas da rede representam as seis condições possíveis da máquina.


Figura 30 - Modelo de rede neural artificial de camada oculta única.



Fonte: Adaptado de LIU et al (2018)

Como pode ser observado, um parâmetro importante na aplicação deste tipo de modelo é a escolha do número de neurônios presentes na camada oculta da rede neural. Novamente, como forma de verificar um valor adequado a ser utilizado, verificou-se a influência desse parâmetro no desempenho do modelo. A Figura 31 mostra o resultado do teste realizado, resultando na escolha do número 19 para a quantidade de neurônios na camada oculta.

Figura 31 - Relação desempenho (acurácia) × número de neurônios na camada oculta da rede neural artificial.



Fonte: Elaborado pelo autor

Além disso, o parâmetro conhecido por *learning rate*, responsável por definir o passo do algoritmo de otimização (gradiente descendente, por exemplo) foi definido como 0,01 (RASCHKA; MIRJALILI, 2017) e 1000 iterações do algoritmo de *backpropagation* foram aplicadas para a fase de treinamento do classificador.

4 ANÁLISE DOS RESULTADOS EXPERIMENTAIS

Este capítulo trata da análise dos resultados das etapas de treinamento e teste dos classificadores analisados. A seção 4.1 traz os resultados individuais de cada método, apresentando suas matrizes confusão e taxas de acurácia e sensibilidade. Por fim, na seção 4.2, todos os cinco métodos são comparados através da aplicação de testes estatísticos, resultando na ordenação dos classificadores por ordem de desempenho.

4.1 DESEMPENHO DOS CLASSIFICADORES⁴

As próximas subseções descrevem os resultados de performance (acurácia e sensibilidade) dos cinco métodos analisados, além das matrizes confusão correspondentes. Para que os resultados apresentados não sejam determinísticos (ou seja, sejam extraídos a partir de somente uma realização de treinamento/teste), os procedimentos de treinamento e teste de cada classificador foram executados 50 vezes, considerando conjuntos diferentes de dados de treinamento para cada execução.

As 50 realizações das etapas de treinamento e teste foram executadas da seguinte forma: na primeira execução separou-se 80% de cada classe para o conjunto de treinamento e os 20% restantes dos casos para realização dos testes; na segunda realização, selecionou-se também 80% para treinamento, mas garantindo que pelo menos 30% dos sinais escolhidos são diferentes dos que foram utilizados na primeira realização. Esse procedimento foi repetido para todas as realizações, sendo os conjuntos de dados de treinamento e teste separados através de sorteio aleatório (já implementado em Python).

Um ponto importante considerado para o treinamento de todos os classificadores foi garantir que os sinais derivados de um determinado sinal normal original não sejam distribuídos nos conjuntos de treinamento e teste, pois assim haveria informações de um mesmo caso normal em ambos os conjuntos, “contaminando” os resultados observados de acurácia e sensibilidade.

4.1.1 Classificador Regressão Logística

As Tabelas 5 a 10 apresentam as matrizes confusão para cada condição da máquina, considerando as 50 realizações do processo de

⁴ Os valores apresentados nessa seção encontram-se no formato *média ± desvio padrão*

treinamento e testes. A acurácia calculada para o método de regressão logística é igual a $85,68\% \pm 1,10\%$ e a sua sensibilidade equivale a $57,00\% \pm 3,17\%$.

Tabela 5 - Matriz confusão – Regressão Logística - Condição Normal.

| | |
|------------------------|-------------------------|
| $V_P = 9,64 \pm 3,65$ | $F_N = 17,60 \pm 3,31$ |
| $F_P = 26,64 \pm 5,92$ | $V_N = 123,46 \pm 5,57$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 6- Matriz confusão – Regressão Logística - Desbalanceamento

| | |
|------------------------|-------------------------|
| $V_P = 21,10 \pm 3,48$ | $F_N = 8,56 \pm 3,61$ |
| $F_P = 9,08 \pm 4,35$ | $V_N = 138,60 \pm 7,01$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 7 - Matriz confusão – Regressão Logística – Desalinhamento Vertical

| | |
|------------------------|-------------------------|
| $V_P = 18,22 \pm 3,01$ | $F_N = 12,36 \pm 4,33$ |
| $F_P = 13,68 \pm 5,54$ | $V_N = 133,08 \pm 7,45$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 8- Matriz confusão – Regressão Logística – Desalinhamento Horizontal

| | |
|------------------------|-------------------------|
| $V_P = 14,34 \pm 3,15$ | $F_N = 16,44 \pm 3,78$ |
| $F_P = 22,88 \pm 3,84$ | $V_N = 123,68 \pm 5,27$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 9- Matriz confusão – Regressão Logística – Mancal de rolamento na posição invertida

| | |
|------------------------|-------------------------|
| $V_P = 24,88 \pm 3,72$ | $F_N = 4,80 \pm 1,81$ |
| $F_P = 0,20 \pm 0,40$ | $V_N = 147,46 \pm 6,01$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 10 - Matriz confusão – Regressão Logística – Mancal de rolamento na posição não invertida

| | |
|------------------------|-------------------------|
| $V_P = 13,04 \pm 3,19$ | $F_N = 16,36 \pm 3,87$ |
| $F_P = 3,64 \pm 1,90$ | $V_N = 144,30 \pm 6,08$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

4.1.2 Classificador k -NN

As Tabelas 11 a 16 correspondem às matrizes confusão para este método. Observa-se o valor de acurácia de $96,78\% \pm 0,71\%$ e o de sensibilidade como $90,16\% \pm 2,18\%$.

Tabela 11 - Matriz confusão - k -NN - Condição Normal

| | |
|------------------------|-------------------------|
| $V_P = 21,80 \pm 3,16$ | $F_N = 5,64 \pm 2,08$ |
| $F_P = 0,30 \pm 0,53$ | $V_N = 149,84 \pm 4,95$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 12 - Matriz confusão - k -NN - Desbalanceamento

| | |
|------------------------|-------------------------|
| $V_P = 27,76 \pm 4,68$ | $F_N = 2,12 \pm 1,42$ |
| $F_P = 1,58 \pm 1,28$ | $V_N = 146,12 \pm 6,05$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 13 - Matriz confusão - k -NN - Desalinhamento Vertical

| | |
|------------------------|-------------------------|
| $V_P = 28,20 \pm 4,08$ | $F_N = 1,64 \pm 1,14$ |
| $F_P = 2,44 \pm 1,53$ | $V_N = 145,30 \pm 6,51$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 14- Matriz confusão - k -NN - Desalinhamento Horizontal

| | |
|------------------------|-------------------------|
| $V_P = 26,56 \pm 5,12$ | $F_N = 3,20 \pm 1,79$ |
| $F_P = 9,16 \pm 2,93$ | $V_N = 138,66 \pm 6,10$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 15- Matriz confusão - k -NN - Mancal de rolamento na posição invertida

| | |
|------------------------|-------------------------|
| $V_P = 27,96 \pm 3,27$ | $F_N = 1,88 \pm 1,33$ |
| $F_P = 1,20 \pm 1,11$ | $V_N = 146,54 \pm 6,92$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 16 - Matriz confusão - k -NN - Mancal de rolamento na posição não invertida

| | |
|------------------------|-------------------------|
| $V_P = 28,16 \pm 3,42$ | $F_N = 2,66 \pm 1,70$ |
| $F_P = 2,46 \pm 1,55$ | $V_N = 144,30 \pm 6,08$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

4.1.3 Classificador SVM

As Tabelas 17 a 22 exibem as matrizes confusão para o método. A acurácia observada foi de $86,68\% \pm 1,04\%$, e sua sensibilidade $60,26\% \pm 2,92\%$.

Tabela 17- Matriz confusão - SVM - Condição Normal

| | |
|------------------------|-------------------------|
| $V_P = 12,48 \pm 2,33$ | $F_N = 14,90 \pm 3,25$ |
| $F_P = 29,40 \pm 3,93$ | $V_N = 119,66 \pm 5,46$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 18 - Matriz confusão - SVM - Desbalanceamento

| | |
|------------------------|-------------------------|
| $V_P = 18,02 \pm 3,03$ | $F_N = 11,56 \pm 3,62$ |
| $F_P = 2,44 \pm 1,56$ | $V_N = 144,42 \pm 5,89$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 19 - Matriz confusão - SVM - Desalinhamento Vertical

| | |
|------------------------|-------------------------|
| $V_P = 25,30 \pm 3,18$ | $F_N = 4,50 \pm 2,41$ |
| $F_P = 17,44 \pm 4,43$ | $V_N = 129,20 \pm 5,56$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 20- Matriz confusão - SVM - Desalinhamento Horizontal

| | |
|------------------------|-------------------------|
| $V_P = 12,52 \pm 2,79$ | $F_N = 18,12 \pm 3,85$ |
| $F_P = 18,76 \pm 2,91$ | $V_N = 127,04 \pm 5,86$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 21- Matriz confusão - SVM - Mancal de rolamento na posição invertida

| | |
|------------------------|-------------------------|
| $V_P = 24,50 \pm 3,70$ | $F_N = 4,88 \pm 2,09$ |
| $F_P = 0,10 \pm 0,02$ | $V_N = 147,06 \pm 5,60$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 22 - Matriz confusão - SVM - Mancal de rolamento na posição não invertida

| | |
|------------------------|-------------------------|
| $V_P = 13,12 \pm 2,73$ | $F_N = 16,54 \pm 3,43$ |
| $F_P = 2,46 \pm 1,83$ | $V_N = 144,32 \pm 6,20$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

4.1.4 Classificador Naive Bayes

A aplicação do classificador Naive Bayes resultou nas matrizes confusão das Tabelas 23 a 28. Calculou-se um valor de $89,72\% \pm 1,03\%$ para a acurácia e $69,16\% \pm 2,63\%$ para sensibilidade.

Tabela 23- Matriz confusão - Naive Bayes - Condição Normal

| | |
|------------------------|-------------------------|
| $V_P = 13,60 \pm 2,01$ | $F_N = 14,48 \pm 1,99$ |
| $F_P = 0 \pm 0$ | $V_N = 149,50 \pm 3,74$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 24 - Matriz confusão - Naive Bayes - Desbalanceamento

| | |
|------------------------|-------------------------|
| $V_P = 27,38 \pm 4,11$ | $F_N = 2,56 \pm 1,49$ |
| $F_P = 6,38 \pm 2,62$ | $V_N = 141,26 \pm 6,30$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 25 - Matriz confusão - Naive Bayes - Desalinhamento Vertical

| | |
|------------------------|-------------------------|
| $V_P = 15,30 \pm 3,20$ | $F_N = 15,82 \pm 3,62$ |
| $F_P = 17,12 \pm 2,96$ | $V_N = 129,34 \pm 5,86$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 26- Matriz confusão - Naive Bayes - Desalinhamento Horizontal

| | |
|------------------------|-------------------------|
| $V_P = 24,84 \pm 3,79$ | $F_N = 3,84 \pm 1,99$ |
| $F_P = 23,48 \pm 4,13$ | $V_N = 125,42 \pm 7,01$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 27- Matriz confusão - Naive Bayes - Mancal de rolamento na posição invertida

| | |
|------------------------|-------------------------|
| $V_P = 27,12 \pm 3,59$ | $F_N = 3,24 \pm 1,55$ |
| $F_P = 2,02 \pm 1,48$ | $V_N = 145,20 \pm 5,62$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 28 - Matriz confusão - Naive Bayes - Mancal de rolamento na posição não invertida

| | |
|------------------------|-------------------------|
| $V_P = 14,58 \pm 3,22$ | $F_N = 14,82 \pm 3,22$ |
| $F_P = 5,76 \pm 2,78$ | $V_N = 142,42 \pm 6,44$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

4.1.5 Classificador Rede Neural Artificial

O classificador rede neural artificial apresentou $95,15\% \pm 0,68\%$ de acurácia e $88,34\% \pm 2,64\%$ de sensibilidade. As matrizes confusão para este método estão representadas nas Tabelas 29 a 34.

Tabela 29- Matriz confusão - RNA - Condição Normal

| | |
|------------------------|-------------------------|
| $V_P = 25,34 \pm 3,71$ | $F_N = 0,66 \pm 3,71$ |
| $F_P = 0,50 \pm 0,75$ | $V_N = 153,50 \pm 0,75$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 30 - Matriz confusão - RNA - Desbalanceamento

| | |
|------------------------|-------------------------|
| $V_P = 34,68 \pm 5,32$ | $F_N = 2,32 \pm 5,32$ |
| $F_P = 2,98 \pm 3,55$ | $V_N = 140,02 \pm 3,55$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 31 - Matriz confusão - RNA - Desalinhamento Vertical

| | |
|------------------------|-------------------------|
| $V_P = 20,48 \pm 3,90$ | $F_N = 4,52 \pm 3,90$ |
| $F_P = 6,12 \pm 3,36$ | $V_N = 148,88 \pm 3,36$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 32- Matriz confusão - RNA - Desalinhamento Horizontal

| | |
|------------------------|-------------------------|
| $V_P = 26,84 \pm 4,25$ | $F_N = 4,16 \pm 4,24$ |
| $F_P = 10,60 \pm 4,31$ | $V_N = 138,40 \pm 4,31$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 33- Matriz confusão - RNA - Mancal de rolamento na posição invertida

| | |
|------------------------|--------------------------|
| $V_P = 22,66 \pm 0,65$ | $F_N = 1,34 \pm 0,65$ |
| $F_P = 4,60 \pm 21,66$ | $V_N = 151,40 \pm 21,64$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

Tabela 34 - Matriz confusão - RNA - Mancal de rolamento na posição não invertida

| | |
|------------------------|-------------------------|
| $V_P = 23,86 \pm 4,75$ | $F_N = 13,14 \pm 4,72$ |
| $F_P = 1,34 \pm 1,49$ | $V_N = 141,66 \pm 1,47$ |

Nota: Número de verdadeiros positivos reais na fase de testes: 30

Número de verdadeiros negativos reais na fase de testes: 150

Fonte: Elaborado pelo autor.

4.2 COMPARAÇÃO DA PERFORMANCE ENTRE OS DIFERENTES MÉTODOS

Com os valores de acurácia e sensibilidade conhecidos para cada método aplicado, é possível ordená-los por ordem de desempenho. O resultado é apresentado na Tabela 35.

Tabela 35 - Comparação de desempenho entre as cinco técnicas analisadas.

| Método | Acurácia [%] | Sensibilidade [%] |
|-------------------|---------------------|--------------------------|
| 1. <i>k</i> -NN | 96,78 ± 0,71 | 90,16 ± 2,18 |
| 2. Redes Neurais | 95,15 ± 0,68 | 88,34 ± 2,64 |
| 3. Naive Bayes | 89,72 ± 1,03 | 69,16 ± 2,63 |
| 4.SVM | 86,68 ± 1,64 | 60,26 ± 2,92 |
| 5. Reg. Logística | 85,68 ± 1,10 | 57,00 ± 3,17 |


Fonte: Elaborado pelo autor.

Assim, com o objetivo de comprovar os resultados obtidos e ter um maior grau de confiança sobre os mesmos, foram aplicados dois modelos de teste estatísticos de hipótese: teste ANOVA e teste t-Student.

4.2.1 Testes estatísticos


Conforme citado anteriormente, foram levantadas cinquenta amostras dos valores de acurácia e sensibilidade para cada modelo de classificador, treinado e testado sob diferentes conjuntos de dados. A Figura 32 apresenta o boxplot de cada um dos métodos utilizados para a métrica de acurácia, enquanto a Figura 33 apresenta o mesmo tipo de diagrama para a sensibilidade.

Figura 32 - Boxplot representando distribuição dos valores de acurácia para cada classificador analisado (n-amostral = 50 para cada método).



Fonte: Elaborado pelo autor

Figura 33 – Boxplot representando distribuição dos valores de sensibilidade para cada classificador analisado (n-amostral = 50 para cada método).



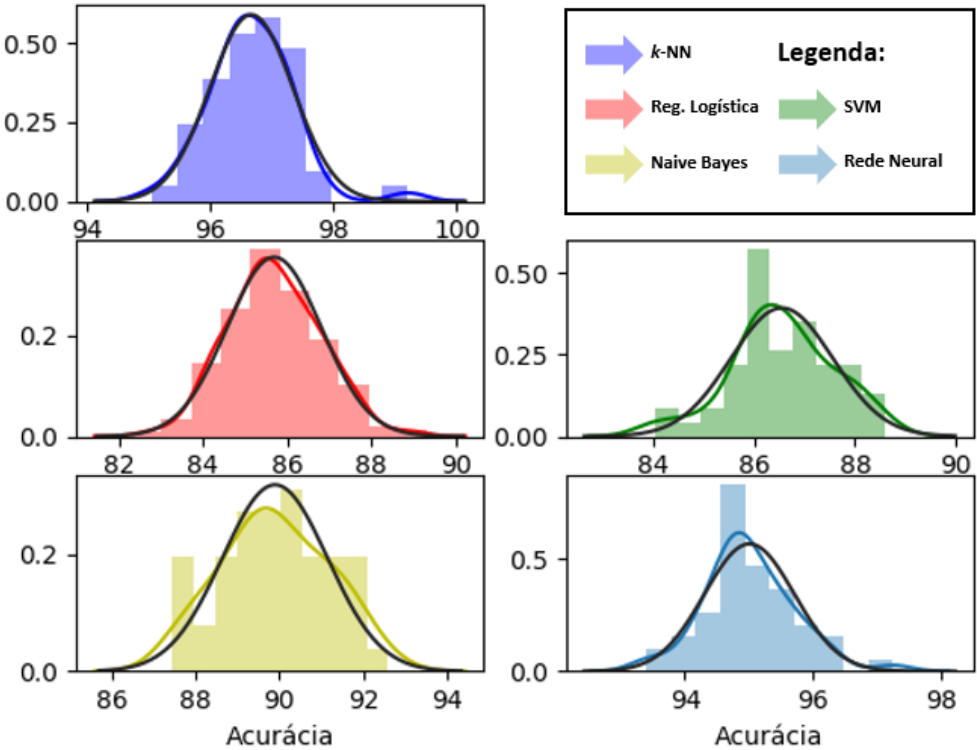
Fonte: Elaborado pelo autor

Um requisito necessário para a aplicação dos testes de hipótese em questão é que o comportamento do conjunto de valores analisado deve seguir a distribuição normal. Para atestar essa condição, foi realizada tanto a inspeção visual da distribuição de cada conjunto de amostras através dos histogramas da Figura 34 (acurácia) e Figura 35 (sensibilidade), como também a aplicação da função *normaltest* da biblioteca *Scipy*, que implementa teste de normalidade (hipótese nula é definida como o conjunto de ocorrências pertencendo à distribuição normal) baseado no trabalho de D'Agostino (1971) e D'Agostino e Pearson (1973). Segundo Karadağ e Altunay (2011), para que seja possível alguma conclusão através do teste ANOVA, no presente caso relativo a 5 conjuntos distintos de métodos, com nível de confiança de 95%, são necessárias no mínimo 25 amostras de cada grupo.⁵

Os resultados obtidos indicam uma distribuição normal para todos os conjuntos testados, tanto para acurácia quanto para sensibilidade, considerando nível de confiança de 95%.

⁵ Nesse trabalho os testes estatísticos foram aplicados considerando um tamanho-amostral igual a 50.

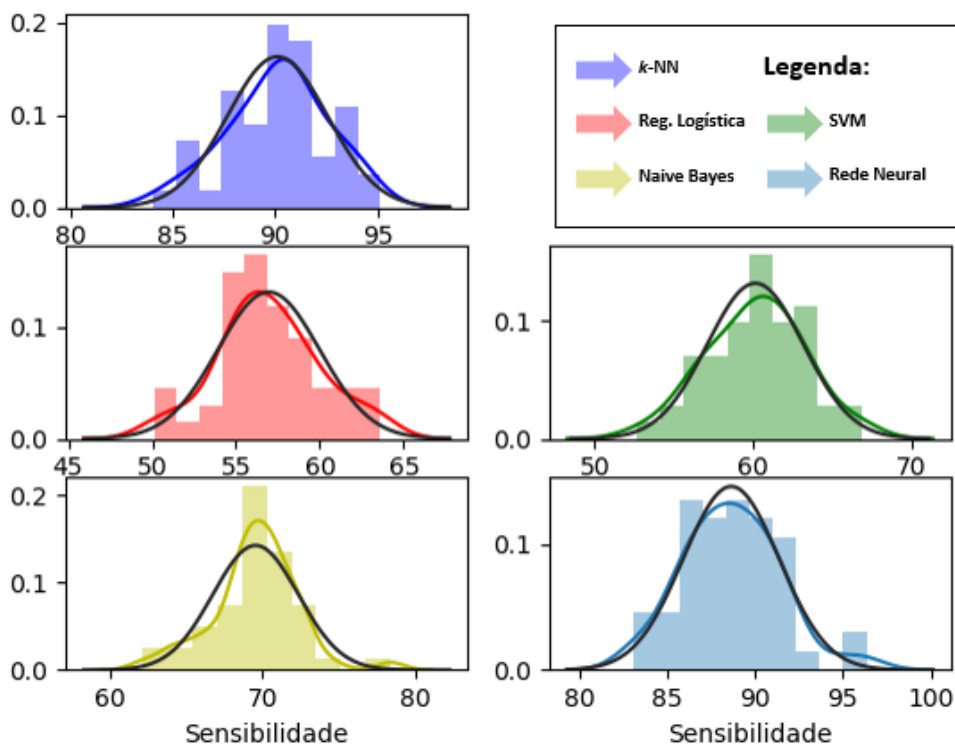
Figura 34 - Histogramas dos valores de acurácia para cada método analisado (n-amostal = 50 para cada classificador).



Nota: Curva preta representa a distribuição gaussiana; Curva colorida representa distribuição aproximada para cada caso, considerando as amostras analisadas.

Fonte: Elaborado pelo autor

Figura 35 - Histogramas dos valores de sensibilidade para cada método analisado (n-amostrai = 50 para cada classificador).



Nota: Curva preta representa a distribuição gaussiana; Curva colorida representa distribuição aproximada para cada caso, considerando as amostras analisadas.

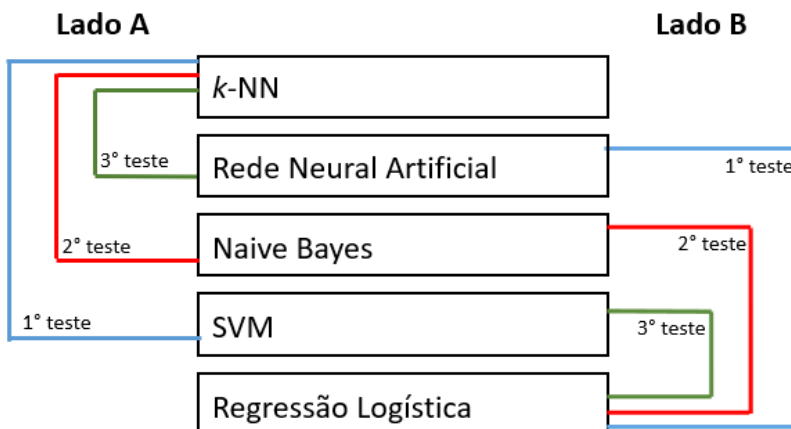
Fonte: Elaborado pelo autor

Com todos os requisitos atendidos, foi adotada a metodologia de testes proposta no trabalho de Irsoy, Yildiz e Alpaydin (2012). Primeiramente, é realizado um teste de análise de variância conhecido como ANOVA. Neste teste, aplicado sobre o conjunto de todos os classificadores, a hipótese nula (a ser verificada) considera que todas as distribuições possuem médias equivalentes, o que caracteriza todo o conjunto analisado como semelhante em função da métrica adotada - vide Equação (11).

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5 \quad (11)$$

Como a hipótese nula foi descartada para este primeiro teste, foi realizada então a segunda etapa da metodologia proposta: aplicação de testes t-Student em pares de classificadores seguindo a ordem exibida na Figura 36.

Figura 36 - Ordem dos testes t-Student pareados proposta por Irsoy, Yildiz e Alpaydin (2012).



Fonte: Elaborado pelo autor.

Para tanto, antes dos testes, os classificadores são ordenados de forma decrescente em relação à sua acurácia e sensibilidade média. Aplicam-se então duas baterias de testes t-Student, uma para cada métrica analisada, (hipótese nula: par de classificadores analisados possuem mesma média em suas amostras e são, portanto, semelhantes). Essa ordenação é interessante pois, segundo os autores, é possível agrupar conjuntos de classificadores semelhantes caso a hipótese nula não seja rejeitada em algum momento. Por exemplo, se o segundo teste do lado A (Figura 36) resultasse em confirmação da hipótese nula, os classificadores *k*-NN, Rede Neural Artificial e Naive Bayes poderiam ser considerados semelhantes.

Entretanto, o conjunto de testes efetuados resultaram na rejeição da hipótese nula para todos os casos. Assim, os métodos analisados podem ser considerados distintos quanto à sua performance. Conclui-se,

portanto, que o método k -NN apresenta os melhores resultados de classificação dentro do espectro de estruturas e parâmetros analisados.

5 CONCLUSÃO

Ao longo deste trabalho foi realizado o estudo dos principais conceitos que envolvem a manutenção preditiva de ativos elétricos, destacando-se o uso de técnicas de inteligência artificial para aplicação no diagnóstico de defeitos em máquinas elétricas rotativas. Um cenário de simulações foi proposto com o objetivo de analisar o desempenho de cinco métodos diferentes - k -NN, Naive Bayes, SVM, Regressão Logística e Redes Neurais Artificiais - para classificação do estado de “saúde” da máquina. Para isso, foram processados e analisados os dados da base MAFAULDA. Por fim, para comparar o desempenho dos diferentes métodos, foram utilizadas as métricas de acurácia e sensibilidade (calculadas a partir das matrizes confusão resultantes dos testes) e testes estatísticos de hipótese, para assegurar diferença estatística entre os métodos analisados.

Apresenta-se, por fim, a ordem dos melhores métodos de classificação aplicados ao diagnóstico de defeitos em máquinas rotativas, considerando-se a acurácia e sensibilidade como métricas de desempenho:

1. k -NN
2. Rede Neural Artificial
3. Naive Bayes
4. SVM
5. Regressão Logística

O resultado do estudo realizado enfatiza a aplicabilidade de tais métodos de inteligência artificial em aplicações voltadas à manutenção preditiva. Com o uso destes, é possível alcançar resultados significativos, com acurácia e sensibilidade acima dos 90%,. Dessa forma, permitindo a identificação de diversos tipos de falhas distintas. Ressalta-se, contudo, a necessidade da obtenção de dados históricos suficientes para treinamento e testes dos classificadores.

5.1 SUGESTÕES PARA FUTUROS TRABALHOS

Essa seção destaca assuntos interessantes da área de aplicação do trabalho realizado, mas que não foram abordados durante seu desenvolvimento em decorrência da limitação de tempo e dos objetivos iniciais. Apresentam-se, portanto, como sugestões para futuras pesquisas:

- Otimização dos métodos de inteligência artificial utilizados, como o desenvolvimento e aplicação de

técnicas para melhor escolha dos hiperparâmetros (parâmetros internos) de cada método.

- Adoção de outras metodologias para a escolha otimizada do vetor de características (*principal component analysis* - PCA, por exemplo).
- Considerar outras métricas, além da acurácia e sensibilidade, para comparação de desempenho entre os classificadores.
- Abranger outros métodos de inteligência artificial existentes, como redes neurais profundas (*deep learning*), por exemplo.
- No contexto da Universidade Federal de Santa Catarina, realizar conjunto de simulações em laboratório para criação de uma base de dados própria de defeitos mecânicos em máquinas rotativas. Trata-se de uma proposta interessante tanto para área de análise e processamento de sinais como também instrumentação eletrônica.

REFERÊNCIAS

- AQX INSTRUMENTAÇÃO ELETRÔNICA. **Plano de negócios 2008-2012**. [S.l.]. 2007.
- BLOCH, H. P.; GEITNER, F. K. **Machinery Component Maintenance and Repair**. 3. ed. Burlington: Gulf Professional Publishing, v. 3, 2005.
- BONALDI, E. L., **Diagnóstico preditivo de avarias em motores de indução trifásicos com MCSA e teoria de conjuntos aproximados**. Dissertação (Mestrado), Universidade Federal de Itajubá, 2005.
- CICHELERO, Mateus. **Relatório de estágio: Desenvolvimento e Manutenção de Software para Solução em Monitoração de Geradores de Energia Elétrica**. AQTech Engenharia e Instrumentação. Florianópolis. 2017.
- CWRU (EUA). **Case Western Reserve University Bearing Database**. Disponível em: <https://csegroups.case.edu/bearingdatacenter>. Acesso em: 23 jun. 2018.
- D'AGOSTINO, R. B. **An omnibus test of normality for moderate and large sample size**. *Biometrika*, 58, 341-348. 1971.
- D'AGOSTINO, R.; PEARSON, E. S. **Tests for departure from normality**. *Biometrika*, 60, 613-622. 1973.
- DREISEITL, Stephan; OHNO-MACHADO, Lucila. Logistic regression and artificial neural network classification models: a methodology review. **Journal of Biomedical Informatics**, issue 5-6, v. 35, p.352-359, oct. 2002. Elsevier BV.
- ELFORJANI, Mohamed; SHANBR, Suliman. Prognosis of Bearing Acoustic Emission Signals Using Supervised Machine Learning. **IEEE Transactions on Industrial Electronics**, [s.l.], v. 65, n. 7, p.5864-5871, jul. 2018. Institute of Electrical and Electronics Engineers (IEEE). <http://dx.doi.org/10.1109/tie.2017.2767551>.

FERRAZ, Ú. B. **SIMULADOR DE FALHAS MECÂNICAS PARA BANCADA DE ANÁLISE DE VIBRAÇÕES**. Universidade Federal de Minas Gerais. Belo Horizonte, p. 101. 2013.

FITZGERALD, A. E.; KINGSLEY JUNIOR, Charles; UMANS, Stephen D.. **Electric Machinery**. 6. ed. Boston: Mcgraw-hill Company, 2003. 688 p.

FREITAS, F. L. **Gestão da Manutenção**. Palhoça: UnisulVirtual, 2012.

GARCIA, M. S. **Análise de defeitos em sistemas mecânicos rotativos a partir da monitoração de vibrações**. 2005. Dissertação (Mestrado), Universidade Federal do Rio de Janeiro, 2005.

GIL, A. C.. **Como elaborar projetos de pesquisa**. São Paulo: Atlas, 1991.

GOODFELLOW, I.; BENGIO, Y.; COURVILL, A.. **Deep Learning**. London: N, 2016.

IBM. **How SVM Works**. Disponível em: <https://www.ibm.com/support/knowledgecenter/pt-br/SS3RA7_17.1.0/modeler_mainhelp_client_ddita/clementine/svm_howwork.html>. Acesso em: 22 jun. 2018.

IRSOY, O.; YILDIZ, O. T.; ALPAYDIN, E.. Design and Analysis of Classifier Learning Experiments in Bioinformatics: Survey and Case Studies. **IEEE/ACM Transactions On Computational Biology And Bioinformatics**, [s.l.], v. 9, n. 6, p.1663-1675, nov. 2012. Institute of Electrical and Electronics Engineers (IEEE). <http://dx.doi.org/10.1109/tcbb.2012.117>.

INTERNATIONAL STANDART. **ISO 13373-1: Condition monitoring and diagnostics of machines - Vibration condition monitoring - Part 1: General procedures**. Suíça. 2002.

INTERNATIONAL STANDART. **ISO 13373-2: Condition monitoring and diagnostics of machines - Vibration condition monitoring - Part 2: Processing, analysis and presentation of vibration data**. Suíça. 2016.

INTERNATIONAL STANDART. **ISO 13379-2: Condition monitoring and diagnostics of machines - Data interpretation and diagnostics techniques - Part 2: Data-driven applications**. Suíça. 2015.

KARADAĞ, Ö.; ALTUNAY, S. A.. Optimal Sample Size Determination for the ANOVA Designs. **International Journal Of Applied Mathematics And Statistics**, Turquia, v. 25, p.127-134, dez. 2011.

LATHI, B.P. **Sinais e Sistemas Lineares**. 2. ed. Porto Alegre: Bookman, 2007. 856 p.

LIU, R. et al. Artificial intelligence for fault diagnosis of rotating machinery: A review. **Mechanical Systems And Signal Processing**, [s.l.], v. 108, p.33-47, ago. 2018. Elsevier BV. <http://dx.doi.org/10.1016/j.ymssp.2018.02.016>.

LÓPEZ, R. Z.. **Classificação automática de defeitos em máquinas rotativas**. 2014. 120 f. TCC (Graduação) - Curso de Engenharia Eletrônica e de Computação, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2014.

MATSUO, T. K.. **Método de análise de vibrações para identificação de falhas em máquinas rotativas de geração de energia elétrica**. 2017. 161 f. Dissertação (Mestrado) - Curso de Mecatrônica, Instituto Federal de Educação, Ciência e Tecnologia de Santa Catarina, Florianópolis, 2017.

MONTGOMERY, D. C., RUNGER, G. C., HUBELE, N. F. **Estatística Aplicada à Engenharia**, 2ª ed., Rio de Janeiro: LTC, 2004.

NEVES, L.; GIL, N.. **Máquinas Elétricas**. Apostila do Curso de Engenharia Elétrica da Escola Superior de Tecnologia e Gestão - Instituto Politécnico de Leiria, 2000.

PYTHON SOFTWARE FOUNDATION. **Python**. 2018. Disponível em: <<https://www.python.org>>. Acesso em: 21 jun. 2018.

RANDALL, R. B. **Vibration-based Condition Monitoring**. 1. ed. Chichester: John Wiley & Sons, Ltd, 2011.

RASCHKA, S. . **Naive Bayes and Text Classification I**, 2014.

RASCHKA, S.; MIRJALILI, V.. **Python Machine Learning**. 2^a ed., Birmingham, UK: Packt Publishing, 2017.

SCIKIT-LEARN. **Model evaluation: quantifying the quality of predictions**. 2018. Disponível em: <http://scikit-learn.org/stable/modules/model_evaluation.html#accuracy-score>. Acesso em: 20 set. 2018

SHENG, S. (Estados Unidos). National Renewable Energy Laboratory (Ed.). **Wind Turbine Gearbox Condition Monitoring Round Robin Study – Vibration Analysis**. Golden, Colorado, 2012. 157 p.

SILVA, E. L. D.; MENEZES, E. M.. **Metodologia da Pesquisa e Elaboração de Dissertação**. 4. ed. Florianópolis: Universidade Federal de Santa Catarina Ufsc, 2005. 139 p.

SMT. **MAFAULDA: Machinery Fault Database** [Online]. 2017. Disponível em: <<http://www02.smt.ufrj.br/~offshore/mfs/index.html#TOC1>>. Acesso em: 20 jun. 2018.

SPANER, F. R., **Técnicas preditivas de manutenção de máquinas rotativas**. 2009. Dissertação (Mestrado), Universidade Federal do Rio de Janeiro, 2009.

SULIMAN, Alaeldin; ZHANG, Yun. A Review on Back-Propagation Neural Networks in the Application of Remote Sensing Image Classification. **Journal Of Earth Science And Engineering**, [s.l.], v. 5, n. 1, p.52-65, 25 jan. 2015. David Publishing Company. <http://dx.doi.org/10.17265/2159-581x>.

SZYMON, A. A., PIETA, F., **Bancada didática de alinhamento de máquinas rotativas**. Dissertação (Mestrado), Universidade Tecnológica Federal do Paraná, 2011.

U.S. DEPARTMENT OF ENERGY. **Federal Energy Management Program, Operations & Maintenance Best Practices: A Guide to Achieving Operational Efficiency**, Release 3. 2010.

WORLD ECONOMIC FORUM, 2016, Suíça. **Digital Transformation of Industries: Electricity**. Genebra. 2016. 32 p

APÊNDICE A – Algoritmo de pré-processamento para condição normal

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.fftpack import fft
import pandas as pd
#####
#Função SeparaSinal
##Entrada: sinal
##Saída: estrutura com oito sinais 31250 x 1
def separaSinal(sinal):
    #numero de linhas de cada um dos oito sinais derivados
    nLinhas = 31250
    #aloca espaço para os sinais
    a = pd.DataFrame(index=np.arange(0, nLinhas), columns='')
    b = pd.DataFrame(index=np.arange(0, nLinhas), columns='')
    c = pd.DataFrame(index=np.arange(0, nLinhas), columns='')
    d = pd.DataFrame(index=np.arange(0, nLinhas), columns='')
    e = pd.DataFrame(index=np.arange(0, nLinhas), columns='')
    f = pd.DataFrame(index=np.arange(0, nLinhas), columns='')
    g = pd.DataFrame(index=np.arange(0, nLinhas), columns='')
    h = pd.DataFrame(index=np.arange(0, nLinhas), columns='')
    #separa sinais
    i = 0
    for x in range(31250):
        a.loc[x] = (sinal.loc[i])
        b.loc[x] = (sinal.loc[i+1])
        c.loc[x] = (sinal.loc[i+2])
        d.loc[x] = (sinal.loc[i+3])
        e.loc[x] = (sinal.loc[i+4])
        f.loc[x] = (sinal.loc[i+5])
        g.loc[x] = (sinal.loc[i+6])
        h.loc[x] = (sinal.loc[i+7])
        i = (i+8)
    sinaisSeparados = [a,b,c,d,e,f,g,h]
    return sinaisSeparados;
```

```

#Função CalculaFFT - usar para os acelerômetros
##Entrada: sinal(sinal a ser analisado), N(numero de amostras),
#T(período de amostragem), freqRotacao
##Saída: |Rf| , |2Rf| e |3Rf|
def calculaFFT(sinal, nAmostras, periodo, frequenciaRotacao):

    #create array that corresponds to values in signal
    y = sinal
    #perform FFT on signal
    yf = fft(y)
    #create new x-axis: frequency from signal
    xf = np.linspace(0.0, 1.0/(2.0*periodo), nAmostras//2)
    yf2 = 2.0/nAmostras * np.abs(yf[0:nAmostras//2])

    dados = {'freq':xf,'magnitude':yf2}
    dframe = pd.DataFrame(data=dados)

    #Pegar valor de amplitude de acordo com frequencia
    #Varrer valores ao redor procurando pelo maior (Rf,2Rf,3Rf)
    #Retornar esses valores
    rf = dframe['magnitude'].where((dframe['freq'] > (frequenciaRotacao - 5))
    & (dframe['freq'] < (frequenciaRotacao + 5)));
    rf2 = dframe['magnitude'].where((dframe['freq'] > (2 * frequenciaRotacao - 5))
    & (dframe['freq'] < (2 * frequenciaRotacao + 5)));
    rf3 = dframe['magnitude'].where((dframe['freq'] > (3 * frequenciaRotacao - 5))
    & (dframe['freq'] < (3 * frequenciaRotacao + 5)));

    amplitudeRf = rf.max()
    amplitude2Rf = rf2.max()
    amplitude3Rf = rf3.max()

    amplitudeHarmonicas = [amplitudeRf,amplitude2Rf,amplitude3Rf]

    return amplitudeHarmonicas;

```

```
#####
#Função PréProcessamento Normal
##Entrada: nome arquivo
##Saída: CSV com 19 colunas: Modulo de Rf, 2Rf e 3Rf para cada acelerometro + Rf
def preprocessamentoNormal(nomeArquivoCSV):
    #####
    #Importa Arquivo CSV
    originalImportadoCSV = pd.read_csv(nomeArquivoCSV, names=['tachometer','uba_axial',
    'uba_radial','uba_tangencial','oba_axial','oba_radial','oba_tangencial','microfone'])
    tacometro = originalImportadoCSV[originalImportadoCSV.columns[0]]
    #####
    global contador
    #####
    #FFT Tacometro Original
    #number of sample points
    N = 250000
    #frequency of signal (in Hz)
    T = 0.00002
    #create array that corresponds to values in signal
    y = tacometro
    #perform FFT on signal
    yf = fft(y)
    #create new x-axis: frequency from signal
    xf = np.linspace(0.0, 1.0/(2.0*T), N//2)
    yf2 = 2.0/N * np.abs(yf[0:N//2])
    #Separa forma decrescente sinal FFT
    dados = {'freq':xf,'magnitude':yf2}
    dfame = pd.DataFrame(data=dados)
    df_descendente = dfame.sort_values('magnitude',ascending = False)
    freqRotacao = df_descendente['freq'].iloc[0]
    #####
    harmonicas = pd.DataFrame(index=np.arange(0,8),columns=[''])
    auxiliarHarmonicas = pd.DataFrame(index=np.arange(0,8),columns=['','',''])

    for i in range(8):
        harmonicas.iloc[i,0] = freqRotacao
    #Loop que percorrerá os 6 acelerometros
    for index in range(6):
        sinalAcelerometro = originalImportadoCSV[originalImportadoCSV.columns[index+1]]
        #Adiciona ruido gaussiano
        mu, sigma = 0,1
        noise = np.random.normal(mu,sigma,sinalAcelerometro.shape)
        sinal = sinalAcelerometro + noise
        sinal.columns = ['magnitude']
        #Divide sinal em 8 (dizimação, de 250000 para 31250)
        sinaisSeparados = separaSinal(sinal)
        # loop para ir jogando no calculaFFT cada um dos 8 partes
        N = 31250
        #periodo (in s)
        T = 0.00016
        for i in range(8):
            auxiliarHarmonicas.loc[i] = calculaFFT(sinaisSeparados[i].iloc[:,0], N, T, freqRotacao)
        harmonicas = pd.concat([harmonicas,auxiliarHarmonicas],ignore_index= True,axis=1)
        print('#####', (contador/totalacelerometros)*100, '% pronto..')
        contador = contador + 1
    return harmonicas;
```



```
#####
#Função Principal

#usado para acompanhar porcentagem dos dados processados
totalacelerometros = 294 # 6acelerometros* 49arquivos
contador = 1
prefixo = 'normal/'
posfixo = '.csv'

print('#####')
print('Arquivo 1')
tabelaTotal = preprocessamentoNormal('normal/1.csv')
for i in range(48):
    arquivo = (prefixo + str(i+2) + posfixo)
    print('#####')
    print('Arquivo', i+2)
    tabelaTotal = pd.concat([tabelaTotal,preprocessamentoNormal(arquivo)],ignore_index= True,
verify_integrity=False)
    print('Arquivo ', i+2, 'de 2 pronto')
tabelaTotal.columns=['Rf','|Rf_axial1|','|2Rf_axial1|','|3Rf_axial1|','|Rf_radial1|','|2Rf_radial1|',
'|3Rf_radial1|','|Rf_tgl|','|2Rf_tgl|','|3Rf_tgl|','|Rf_axial2|','|2Rf_axial2|','|3Rf_axial2|',
'|Rf_radial2|','|2Rf_radial2|','|3Rf_radial2|','|Rf_tg2|','|2Rf_tg2|','|3Rf_tg2|']
tabelaTotal.to_csv('0_processado/normal/FeaturesNormal.csv', encoding='utf-8',index=False)
```

ANEXO A – Sensores de vibração utilizados na bancada experimental

Figura 37- Acelerômetro industrial IMI Sensors, modelo 601A01



Fonte: LÓPEZ (2014) p. 30

Tabela 36 - Características Acelerômetro 601A01

| | |
|----------------------------|---|
| Sensibilidade | ($\pm 20\%$) 100 mV/g (10,2 mV/(m/s ²)) |
| Faixa de frequência | (± 3 dB) 16-600000 CPM (0,27-10.000 Hz) |
| Faixa de medição | ± 50 g (± 490 m/s ²). |

Fonte: LÓPEZ (2014)

Figura 38 - Acelerômetro triaxial IMI Sensors, modelo 604B31



Fonte: LÓPEZ (2014) p. 31

Tabela 37 - Características Acelerômetro 604B31

| | |
|----------------------------|---|
| Sensibilidade | ($\pm 20\%$) 100 mV/g (10,2 mV/(m/s ²)) |
| Faixa de frequência | (± 3 dB) 30-300000 CPM (0,5-5000 Hz) |
| Faixa de medição | ± 50 g (± 490 m/s ²). |

Fonte: LÓPEZ (2014)

Figura 39 - Montagem dos acelerômetros no mancal (a) interior e (b) exterior



(a)



(b)

Fonte: LÓPEZ (2014) p.33